

Data Driven Decision Making


Lecture 9 - Analytics Issues in ADP - 日本語訳・詳細解説・試験対策ノート

この PDF は review v5 です。全講義資料へ同じ形式を適用し、各スライドページには元スライド、日本語訳、詳細解説、試験対策ポイント、ページ固有の確認問題と解答を配置しています。過去問は重複を避け、必要な知識を説明した後に独立演習ページとしてまとめています。

Contents

Lecture 9 - Analytics Issues in ADP

Lecture 9 - Analytics Issues in ADP



日本語訳

- データ駆動型意思決定
- 講義 9 –Analytics Issues in 近似動的計画法

試験対策ポイント

- ADP ではデータ生成、特徴量、学習方法、評価が政策品質を左右する。
- feature selection と dimensionality reduction を区別する。

解説

このページでは「Data Driven Decision Making」を理解する。スライド上の表現は短い、試験では定義、具体例、モデル上の意味、手法の限界まで説明できる必要がある。

Analytics Issues in ADP では、ADP を動かすためのデータ分析上の問題を扱う。価値関数や方策を近似するには、状態、決定、外生情報、報酬、遷移のデータが必要である。実データだけでは不足する場合、シミュレーションで学習データを生成することもある。supervised learning は、入力と正解ラベルの対応から予測モデルを学ぶ方法である。VFA では、特徴量を入力し、シミュレーションや DP で得た価値推定をラベルとして学習できる。unsupervised learning は、ラベルなしデータからクラスや低次元構造を見つける。状態集約や需要パターン分類で役立つ。

Feature selection は、既存の候補特徴から重要なものを選ぶことである。例えば車両位置、残り容量、残り時間、遅延注文数のうち、将来価値の説明に効くものを選ぶ。Dimensionality reduction は、既存特徴を組み合わせて新しい低次元表現を作ることである。PCA やオートエンコーダのような方法が該当する。

外生情報の生成では、過去データから分布を推定し、乱数で将来シナリオを生成する。旅行時間、需要発生、サービス時間などをサンプリングすることで、Rollout や VFA 学習に必要な未来パスを作る。ただし、分布仮定が間違っていると学習された方策も現実合わない。

試験では、ADP を単なる最適化手法としてではなく、データ分析・特徴量設計・学習・シミュレーションが組み合わさったシステムとして説明する。特に feature selection と dimensionality reduction の違いは頻出であり、例を添えて説明する。

確認問題と解答


1. **L09-S001: 「Data Driven Decision Making」の概念を、定義・具体例・モデル上の意味の順に説明せよ。**

定義としては、ADP ではデータ生成、特徴量、学習方法、評価が政策品質を左右する。。具体例では、配送・在庫・フードデリバリーのような現実問題を扱い、状態、決定、外生情報、報酬、または情報モデル/意思決定モデルのどこに対応するかを明示する。モデル上の意味として、この概念が目的関数、制約、状態表現、将来価値、または方策選択にどのような影響を与えるかを書く。試験では、用語だけを列挙せず、入力データから意思決定、さらに現実の実装へつながる流れを文章で示すことが重要である。

2. **L09-S001: このスライドの考え方を、講義全体の DDDM プロセスの中に位置づけよ。**

DDDM プロセスでは、現実世界のデータを集約して情報モデルを作り、意思決定モデルまたは方策で行動を選び、実装後に結果を観測して次の状態へ進む。このスライドの概念は、そのどこか一部だけではなく、データ表現、意思決定、将来不確実性、計算可能性のいずれかに関わる。答案では、まずこの概念がどの段階に属するかを述べ、次に他の段階へどう影響するかを書く。例えば価値関数なら将来価値を現在決定へ戻す役割、FIFO なら旅行時間情報モデルの整合性を保証する役割、CFA なら目的関数を調整して将来に良い行動を誘導する役割である。

Data Analytics Issues for ADP Methods



日本語訳

- ADP 手法におけるデータ分析上の論点
- Exogenous Information（この用語は講義スライド上の専門語として扱う）
- Feature Engineering（この用語は講義スライド上の専門語として扱う）
- Endogenous Information（この用語は講義スライド上の専門語として扱う）

試験対策ポイント

- ADP ではデータ生成、特徴量、学習方法、評価が政策品質を左右する。
- feature selection と dimensionality reduction を区別する。

解説

このページでは「Data Analytics Issues for ADP Methods」を理解する。スライド上の表現は短い、試験では定義、具体例、モデル上の意味、手法の限界まで説明できる必要がある。

Analytics Issues in ADP では、ADP を動かすためのデータ分析上の問題を扱う。価値関数や方策を近似するには、状態、決定、外生情報、報酬、遷移のデータが必要である。実データだけでは不足する場合、シミュレーションで学習データを生成することもある。

supervised learning は、入力と正解ラベルの対応から予測モデルを学ぶ方法である。VFA では、特徴量を入力し、シミュレーションや DP で得た価値推定をラベルとして学習できる。unsupervised learning は、ラベルなしデータからクラスターや低次元構造を見つける。状態集約や需要パターン分類で役立つ。

Feature selection は、既存の候補特徴から重要なものを選ぶことである。例えば車両位置、残り容量、残り時間、遅延注文数のうち、将来価値の説明に効くものを選ぶ。Dimensionality reduction は、既存特徴を組み合わせで新しい低次元表現を作ることである。PCA やオートエンコーダのような方法が該当する。

外生情報の生成では、過去データから分布を推定し、乱数で将来シナリオを生成する。旅行時間、需要発生、サービス時間などをサンプリングすることで、Rollout や VFA 学習に必要な未来パスを作る。ただし、分布仮定が間違っていると学習された方策も現実合わない。

試験では、ADP を単なる最適化手法としてではなく、データ分析・特徴量設計・学習・シミュレーションが組み合わさったシステムとして説明する。特に feature selection と dimensionality reduction の違いは頻出であり、例を添えて説明する。

確認問題と解答

1. **L09-S002: 「Data Analytics Issues for ADP Methods」の概念を、定義・具体例・モデル上の意味の順に説明せよ。**
定義としては、ADP ではデータ生成、特徴量、学習方法、評価が政策品質を左右する。。具体例では、配送・在庫・フードデリバリーのような現実問題を扱い、状態、決定、外生情報、報酬、または情報モデル/意思決定モデルのどこに対応するかを明示する。モデル上の意味として、この概念が目的関数、制約、状態表現、将来価値、または方策選択にどのような影響を与えるかを書く。試験では、用語だけを列挙せず、入力データから意思決定、さらに現実の実装へつながる流れを文章で示すことが重要である。
2. **L09-S002: このスライドの考え方を、講義全体の DDDM プロセスの中に位置づけよ。**
DDDM プロセスでは、現実世界のデータを集約して情報モデルを作り、意思決定モデルまたは方策で行動を選び、実装後に結果を観測して次の状態へ進む。このスライドの概念は、そのどこか一部だけではなく、データ表現、意思決定、将来不確実性、計算可能性のいずれかに関わる。答えでは、まずこの概念がどの段階に属するかを述べ、次に他の段階へどう影響するかを書く。例えば価値関数なら将来価値を現在決定へ戻す役割、FIFO なら旅行時間情報モデルの整合性を保証する役割、CFA なら目的関数を調整して将来に良い行動を誘導する役割である。

Unsupervised vs. Supervised Learning

- Machine Learning differentiates concepts in (un-)supervised learning approaches

- Unsupervised learning** looks at data objects consisting of attributes only
- It then builds a model that describes all data objects in the best possible way
- It stands proxy for descriptive modeling, an illustrative concept is clustering

- Supervised learning** looks at data objects consisting of attributes and (one) variable
- It aims at a mapping of attribute values to one distinct value of the variable
- It learns a suitable mapping from training data, later on it discriminates test data
- It stands proxy for predictive modeling, an illustrative concept is classification

- Attribute/variable types determine e.g. regression (numerical) vs. classification (categorical)



Data Driven Decision Making | Lecture 9 – Analytics Issues in ADP | Page 3



日本語訳

- 教師なし学習と教師あり学習
- Machine Learning differentiates concepts in (un-) 教師あり学習 approaches
- Un 教師あり学習 looks at data objects consisting of attributes only
- It then builds a model that describes all data objects in the best possible way (この用語は講義スライド上の専門語として扱う)
- It stands proxy for descriptive modeling, an illustrative concept is clustering (この用語は講義スライド上の専門語として扱う)
- Supervised learning looks at data objects consisting of attributes and (one) variable (この用語は講義スライド上の専門語として扱う)
- It aims at a mapping of attribute values to one distinct value of the variable (この用語は講義スライド上の専門語として扱う)
- It learns a suitable mapping from training data, later on it discriminates test data (この用語は講義スライド上の専門語として扱う)
- It stands proxy for predictive modeling, an illustrative concept is classification (この用語は講義スライド上の専門語として扱う)

試験対策ポイント

- ADP ではデータ生成、特徴量、学習方法、評価が政策品質を左右する。
- feature selection と dimensionality reduction を区別する。

解説

このページでは「Unsupervised vs. Supervised Learning」を理解する。スライド上の表現は短いが、試験では定義、具体例、モデル上の意味、手法の限界まで説明できる必要がある。

Analytics Issues in ADP では、ADP を動かすためのデータ分析上の問題を扱う。価値関数や方策を近似するには、状態、決定、外生情報、報酬、遷移のデータが必要である。実データだけでは不足する場合、シミュレーションで学習データを生成することもある。

supervised learning は、入力と正解ラベルの対応から予測モデルを学ぶ方法である。VFA では、特徴量を入力し、シミュレーションや DP で得た価値推定をラベルとして学習できる。unsupervised learning は、ラベルなしデータからクラスターや低次元構造を見つける。状態集約や需要パターン分類で役立つ。

Feature selection は、既存の候補特徴から重要なものを選ぶことである。例えば車両位置、残り容量、残り時間、遅延注文数のうち、将来価値の説明に効くものを選ぶ。Dimensionality reduction は、既存特徴を組み合わせて新しい低次元表現を作ることである。PCA やオートエンコーダのような方法が該当する。

外生情報の生成では、過去データから分布を推定し、乱数で将来シナリオを生成する。旅行時間、需要発生、サービス時間などをサンプリングすることで、Rollout や VFA 学習に必要な未来パスを作る。ただし、分布仮定が間違っていると学習された方策も現実合わない。

試験では、ADP を単なる最適化手法としてではなく、データ分析・特徴量設計・学習・シミュレーションが組み合わさったシステムとして説明する。特に feature selection と dimensionality reduction の違いは頻出であり、例を添えて説明する。

確認問題と解答

- L09-S003: 「Unsupervised vs. Supervised Learning」の概念を、定義・具体例・モデル上の意味の順に説明せよ。**

定義としては、ADP ではデータ生成、特徴量、学習方法、評価が政策品質を左右する。。具体例では、配送・在庫・フードデリバリーのような現実問題を扱い、状態、決定、外生情報、報酬、または情報モデル/意思決定モデルのどこに対応するかを明示する。モデル上の意味として、この概念が目的関数、制約、状態表現、将来価値、または方策選択にどのような影響を与えるかを書く。試験では、用語だけを列挙せず、入力データから意思決定、さらに現実の実装へつながる流れを文章で示すことが重要である。

- L09-S003: このスライドの考え方を、講義全体の DDDM プロセスの中に位置づけよ。**

DDDM プロセスでは、現実世界のデータを集約して情報モデルを作り、意思決定モデルまたは方策で行動を選び、実装後に結果を観測して次の状態へ進む。このスライドの概念は、そのどこか一部だけではなく、データ表現、意思決定、将来不確実性、計算可能性のいずれかに関わる。答えでは、まずこの概念がどの段階に属するかを述べ、次に他の段階へどう影響するかを書く。例えば価値関数なら将来価値を現在決定へ戻す役割、FIFO なら旅行時間情報モデルの整合性を保証する役割、CFA なら目的関数を調整して将来に良い行動を誘導する役割である。

We often assume that the data set is provided in form of a simple table

The rows of the table are called **instances, records, samples or data objects**
The columns of the table are called **attributes, features or variables**

日本語訳

- Data Objects (この用語は講義スライド上の専門語として扱う)
- We often assume that the data set is provided in form of a simple table (この用語は講義スライド上の専門語として扱う)
- 教師なし学習教師あり学習
- 0000000000 1...0000000000 0 0000000000 1...0000000000 phase (この用語は講義スライド上の専門語として扱う)
- 0000000000 1 00000011 000001...0000010 00000000 1 0000011 000001...000001 training (この用語は講義スライド上の専門語として扱う)
- ...00000...1 00000...00000...0 ...00000...1 00000...00000...training (この用語は講義スライド上の専門語として扱う)
- 000000000 0 00000001 000000...00000000 00000000 0 0000001 000000...000000 test data (この用語は講義スライド上の専門語として扱う)
- Berthold et al. (2010), Ch. 4.1 (この用語は講義スライド上の専門語として扱う)
- The rows of the table are called instances, records, samples or data objects (この用語は講義スライド上の専門語として扱う)

試験対策ポイント

- ADP ではデータ生成、特徴量、学習方法、評価が政策品質を左右する。
- feature selection と dimensionality reduction を区別する。

解説

このページでは「Data Objects」を理解する。スライド上の表現は短いが、試験では定義、具体例、モデル上の意味、手法の限界まで説明できる必要がある。

Analytics Issues in ADP では、ADP を動かすためのデータ分析上の問題を扱う。価値関数や方策を近似するには、状態、決定、外生情報、報酬、遷移のデータが必要である。実データだけでは不足する場合、シミュレーションで学習データを生成することもある。supervised learning は、入力と正解ラベルの対応から予測モデルを学ぶ方法である。VFA では、特徴量を入力し、シミュレーションや DP で得た価値推定をラベルとして学習できる。unsupervised learning は、ラベルなしデータからクラスターや低次元構造を見つける。状態集約や需要パターン分類で役立つ。

Feature selection は、既存の候補特徴から重要なものを選ぶことである。例えば車両位置、残り容量、残り時間、遅延注文数のうち、将来価値の説明に効くものを選ぶ。Dimensionality reduction は、既存特徴を組み合わせて新しい低次元表現を作ることである。PCA やオートエンコーダのような方法が該当する。

外生情報の生成では、過去データから分布を推定し、乱数で将来シナリオを生成する。旅行時間、需要発生、サービス時間などをサンプリングすることで、Rollout や VFA 学習に必要な未来パスを作る。ただし、分布仮定が間違っていると学習された方策も現実には合わない。

試験では、ADPを単なる最適化手法としてではなく、データ分析・特徴量設計・学習・シミュレーションが組み合わさったシステムとして説明する。特に feature selection と dimensionality reduction の違いは頻出であり、例を添えて説明する。

確認問題と解答

1. **L09-S004: 「Data Objects」の概念を、定義・具体例・モデル上の意味の順に説明せよ。**
 定義としては、ADP ではデータ生成、特徴量、学習方法、評価が政策品質を左右する。具体例では、配送・在庫・フードデリバリーのような現実問題を、状態、決定、外生情報、報酬、または情報モデル/意思決定モデルのどこに対応するかを明示する。モデル上の意味として、この概念が目的関数、制約、状態表現、将来価値、または方策選択にどのような影響を与えるかを書く。試験では、用語だけを列挙せず、入力データから意思決定、さらに現実の実装へつながる流れを文章で示すことが重要である。
2. **L09-S004: このスライドの考え方を、講義全体の DDDM プロセスの中に位置づけよ。**
 DDDM プロセスでは、現実世界のデータを集約して情報モデルを作り、意思決定モデルまたは方策で行動を選び、実装後に結果を観測して次の状態へ進む。このスライドの概念は、そのどこか一部だけではなく、データ表現、意思決定、将来不確実性、計算可能性のいずれかに関わる。答案では、まずこの概念がどの段階に属するかを述べ、次に他の段階へどう影響するかを書く。例えば価値関数なら将来価値を現在決定へ戻す役割、FIFO なら旅行時間情報モデルの整合性を保証する役割、CFA なら目的関数を調整して将来に良い行動を誘導する役割である。

Attribute Scales

- Every attribute has exactly one level of measurement/scale
- Scale defines the types of operations and computations that are allowed for the attribute values

	Scale	Measure property	Mathematical operators	Example
Categorical	Nominal	Classification, membership	=, ≠	Color: red, green, blue, orange
	Ordinal	Comparison, level	>, <	Likert Scale: Like, Like Somewhat, Neutral, Dislike Somewhat, Dislike
Numerical / Cardinal	Interval	Difference, affinity	+, −	Date & Time: 05.00, 08.00, 11.00
	Ratio	Magnitude, amount	×, ÷	Salary: 25.000€, 50.000€, 150.000€

Berthold et al. (2010), Ch. 4.1

日本語訳

- Attribute Scales（この用語は講義スライド上の専門語として扱う）
- □ Every attribute has exactly one level of measurement/scale（この用語は講義スライド上の専門語として扱う）
- □ Scale defines the types of operations and computations that are allowed for the attribute values（この用語は講義スライド上の専門語として扱う）
- Mathematical（この用語は講義スライド上の専門語として扱う）
- Scale Measure property 例
- operators（この用語は講義スライド上の専門語として扱う）
- Classification,（この用語は講義スライド上の専門語として扱う）
- Nominal =, ≠Color: red, green, blue, orange（この用語は講義スライド上の専門語として扱う）
- membership（この用語は講義スライド上の専門語として扱う）

試験対策ポイント

- ADP ではデータ生成、特徴量、学習方法、評価が政策品質を左右する。
- feature selection と dimensionality reduction を区別する。

解説

このページでは「Attribute Scales」を理解する。スライド上の表現は短いが、試験では定義、具体例、モデル上の意味、手法の限界まで説明できる必要がある。

Analytics Issues in ADP では、ADP を動かすためのデータ分析上の問題を扱う。価値関数や方策を近似するには、状態、決定、外生情報、報酬、遷移のデータが必要である。実データだけでは不足する場合、シミュレーションで学習データを生成することもある。

supervised learning は、入力と正解ラベルの対応から予測モデルを学ぶ方法である。VFA では、特徴量を入力し、シミュレーションや DP で得た価値推定をラベルとして学習できる。unsupervised learning は、ラベルなしデータからクラスや低次元構造を見つける。状態集約や需要パターン分類で役立つ。

Feature selection は、既存の候補特徴から重要なものを選ぶことである。例えば車両位置、残り容量、残り時間、遅延注文数のうち、将来価値の説明に効くものを選ぶ。Dimensionality reduction は、既存特徴を組み合わせて新しい低次元表現を作ることである。PCA やオートエンコーダのような方法が該当する。


外生情報の生成では、過去データから分布を推定し、乱数で将来シナリオを生成する。旅行時間、需要発生、サービス時間などをサンプリングすることで、Rollout や VFA 学習に必要な未来パスを作る。ただし、分布仮定が間違っていると学習された方策も現実合わない。

試験では、ADP を単なる最適化手法としてではなく、データ分析・特徴量設計・学習・シミュレーションが組み合わさったシステムとして説明する。特に feature selection と dimensionality reduction の違いは頻出であり、例を添えて説明する。

確認問題と解答

1. **L09-S005: 「Attribute Scales」の概念を、定義・具体例・モデル上の意味の順に説明せよ。**
定義としては、ADP ではデータ生成、特徴量、学習方法、評価が政策品質を左右する。。具体例では、配送・在庫・フードデリバリーのような現実問題を扱い、状態、決定、外生情報、報酬、または情報モデル/意思決定モデルのどこに対応するかを明示する。モデル上の意味として、この概念が目的関数、制約、状態表現、将来価値、または方策選択にどのような影響を与えるかを書く。試験では、用語だけを列挙せず、入力データから意思決定、さらに現実の実装へつながる流れを文章で示すことが重要である。
2. **L09-S005: このスライドの考え方を、講義全体の DDDM プロセスの中に位置づけよ。**
DDDM プロセスでは、現実世界のデータを集約して情報モデルを作り、意思決定モデルまたは方策で行動を選び、実装後に結果を観測して次の状態へ進む。このスライドの概念は、そのどこか一部だけではなく、データ表現、意思決定、将来不確実性、計算可能性のいずれかに関わる。答案では、まずこの概念がどの段階に属するかを述べ、次に他の段階へどう影響するかを書く。例えば価値関数なら将来価値を現在決定へ戻す役割、FIFO なら旅行時間情報モデルの整合性を保証する役割、CFA なら目的関数を調整して将来に良い行動を誘導する役割である。

Exogenous Information



日本語訳

- Exogenous Information（この用語は講義スライド上の専門語として扱う）

試験対策ポイント

- ADP ではデータ生成、特徴量、学習方法、評価が政策品質を左右する。
- feature selection と dimensionality reduction を区別する。

解説

このページでは「Exogenous Information」を理解する。スライド上の表現は短い、試験では定義、具体例、モデル上の意味、手法の限界まで説明できる必要がある。

Analytics Issues in ADP では、ADP を動かすためのデータ分析上の問題を扱う。価値関数や方策を近似するには、状態、決定、外生情報、報酬、遷移のデータが必要である。実データだけでは不足する場合、シミュレーションで学習データを生成することもある。supervised learning は、入力と正解ラベルの対応から予測モデルを学ぶ方法である。VFA では、特徴量を入力し、シミュレーションや DP で得た価値推定をラベルとして学習できる。unsupervised learning は、ラベルなしデータからクラスや低次元構造を見つける。状態集約や需要パターン分類で役立つ。

Feature selection は、既存の候補特徴から重要なものを選ぶことである。例えば車両位置、残り容量、残り時間、遅延注文数のうち、将来価値の説明に効くものを選ぶ。Dimensionality reduction は、既存特徴を組み合わせで新しい低次元表現を作ることである。PCA やオートエンコーダのような方法が該当する。

外生情報の生成では、過去データから分布を推定し、乱数で将来シナリオを生成する。旅行時間、需要発生、サービス時間などをサンプリングすることで、Rollout や VFA 学習に必要な未来パスを作る。ただし、分布仮定が間違っていると学習された方策も現実合わない。

試験では、ADP を単なる最適化手法としてではなく、データ分析・特徴量設計・学習・シミュレーションが組み合わさったシステムとして説明する。特に feature selection と dimensionality reduction の違いは頻出であり、例を添えて説明する。

確認問題と解答

- L09-S006: 「Exogenous Information」の概念を、定義・具体例・モデル上の意味の順に説明せよ。**
定義としては、ADP ではデータ生成、特徴量、学習方法、評価が政策品質を左右する。具体例では、配送・在庫・フードデリバリーのような現実問題を扱い、状態、決定、外生情報、報酬、または情報モデル/意思決定モデルのどこに対応するかを明示する。モデル上の意味として、この概念が目的関数、制約、状態表現、将来価値、または方策選択にどのような影響を与えるかを書く。試験では、用語だけを列挙せず、入力データから意思決定、さらに現実の実装へつながる流れを文章で示すことが重要である。
- L09-S006: このスライドの考え方を、講義全体の DDDM プロセスの中に位置づけよ。**
DDDM プロセスでは、現実世界のデータを集約して情報モデルを作り、意思決定モデルまたは方策で行動を選び、実装後に結果を観測して次の状態へ進む。このスライドの概念は、そのどこか一部だけではなく、データ表現、意思決定、将来不確実性、計算可能性のいずれかに関わる。答えでは、まずこの概念がどの段階に属するかを述べ、次に他の段階へどう影響するかを書く。例えば価値関数なら将来価値を現在決定へ戻す役割、FIFO なら旅行時間情報モデルの整合性を保証する役割、CFA なら目的関数を調整して将来に良い行動を誘導する役割である。

Exogeneous Information

- Little information suggests the use of policy function approx. or cost function approx.
- Anticipation may be achieved by explorative data analysis → derive future costs
- The more you know about exogeneous information, the more useful anticipation becomes
- Detailed exogeneous information suggests look-ahead methods or value function approx.
- Stochastic transitions denoted in the MDP are to be implemented in the simulation
- Transitions may be derived from distributions or they may be sampled from observations
- In the following, there are examples provided for both approaches

日本語訳

- Exogeneous Information（この用語は講義スライド上の専門語として扱う）
- Little information suggests the use of 方策 function approx. or cost function approx.
- Anticipation may be achieved by explorative data analysis □ derive future costs（この用語は講義スライド上の専門語として扱う）
- The more you know about exogeneous information, the more useful anticipation becomes（この用語は講義スライド上の専門語として扱う）
- Detailed exogeneous information suggests 先読み methods or value function approx.
- Stochastic 遷移 s denoted in the MDP are to be implemented in the シミュレーション
- Transitions may be derived from 分布 s or they may be sampled from observations
- In the following, there are examples provided for both approaches（この用語は講義スライド上の専門語として扱う）

試験対策ポイント

- ADP ではデータ生成、特徴量、学習方法、評価が政策品質を左右する。
- feature selection と dimensionality reduction を区別する。

解説

このページでは「Exogeneous Information」を理解する。スライド上の表現は短い、試験では定義、具体例、モデル上の意味、手法の限界まで説明できる必要がある。

Analytics Issues in ADP では、ADP を動かすためのデータ分析上の問題を扱う。価値関数や方策を近似するには、状態、決定、外生情報、報酬、遷移のデータが必要である。実データだけでは不足する場合、シミュレーションで学習データを生成することもある。

supervised learning は、入力と正解ラベルの対応から予測モデルを学ぶ方法である。VFA では、特徴量を入力し、シミュレーションや DP で得た価値推定をラベルとして学習できる。unsupervised learning は、ラベルなしデータからクラスや低次元構造を見つける。状態集約や需要パターン分類で役立つ。

Feature selection は、既存の候補特徴から重要なものを選ぶことである。例えば車両位置、残り容量、残り時間、遅延注文数のうち、将来価値の説明に効くものを選ぶ。Dimensionality reduction は、既存特徴を組み合わせて新しい低次元表現を作ることである。PCA やオートエンコーダのような方法が該当する。

外生情報の生成では、過去データから分布を推定し、乱数で将来シナリオを生成する。旅行時間、需要発生、サービス時間などをサンプリングすることで、Rollout や VFA 学習に必要な未来パスを作る。ただし、分布仮定が間違っていると学習された方策も現実合わない。

試験では、ADP を単なる最適化手法としてではなく、データ分析・特徴量設計・学習・シミュレーションが組み合わさったシステムとして説明する。特に feature selection と dimensionality reduction の違いは頻出であり、例を添えて説明する。

確認問題と解答

- L09-S007: 「Exogeneous Information」の概念を、定義・具体例・モデル上の意味の順に説明せよ。**
定義としては、ADP ではデータ生成、特徴量、学習方法、評価が政策品質を左右する。。具体例では、配送・在庫・フードデリバリーのような現実問題を扱い、状態、決定、外生情報、報酬、または情報モデル/意思決定モデルのどこに対応するかを明示する。モデル上の意味として、この概念が目的関数、制約、状態表現、将来価値、または方策選択にどのような影響を与えるかを書く。試験では、用語だけを列挙せず、入力データから意思決定、さらに現実の実装へつながる流れを文章で示すことが重要である。
- L09-S007: このスライドの考え方を、講義全体の DDDM プロセスの中に位置づけよ。**
DDDM プロセスでは、現実世界のデータを集約して情報モデルを作り、意思決定モデルまたは方策で行動を選び、実装後に結果を観測して次の状態へ進む。このスライドの概念は、そのどこか一部だけではなく、データ表現、意思決定、将来不確実性、計算可能性のいずれかに関わる。答案では、まずこの概念がどの段階に属するかを述べ、次に他の段階へどう影響するかを書く。例えば価値関数なら将来価値を現在決定へ戻す役割、FIFO なら旅行時間情報モデルの整合性を保証する役割、CFA なら目的関数を調整して将来に良い行動を誘導する役割である。

Generating stochastic transition from distribution

- Consider a stochastic transition depicting the elapse of time before the next customer arrives


- Inter-arrival times (between customers) are often depicted by an exponential distribution

$$X \sim \text{Exp}(\theta) : f(x) = \theta e^{-\theta x}$$

- Consider random variable with θ being the scale parameter

$$\begin{aligned} P(X \leq x) &= F(x) = \int_{-\infty}^x f(t) dt \\ &= \int_0^x \theta e^{-\theta t} dt \\ &= -e^{-\theta t} \Big|_0^x \\ &= -(e^{-\theta x} - e^0) \\ &= 1 - e^{-\theta x} \end{aligned}$$

- Cumulative distribution function



https://en.wikipedia.org/wiki/Exponential_distribution

Decision Support
Institut für Wirtschaftsinformatik

日本語訳

- Generating 確率的遷移 from 分布
- Consider a 確率的遷移 depicting the
- elapse of time before the next customer θ (この用語は講義スライド上の専門語として扱う)
- θ
- arrives θ (この用語は講義スライド上の専門語として扱う)
- Inter-arrival times (between customers) are (この用語は講義スライド上の専門語として扱う)
- often depicted by an exponential 分布
- Consider random variable (この用語は講義スライド上の専門語として扱う)
- with □ being the scale parameter (この用語は講義スライド上の専門語として扱う)

試験対策ポイント

- ADP ではデータ生成、特徴量、学習方法、評価が政策品質を左右する。
- feature selection と dimensionality reduction を区別する。

解説

このページでは「Generating stochastic transition from distribution」を理解する。スライド上の表現は短い、試験では定義、具体例、モデル上の意味、手法の限界まで説明できる必要がある。

Analytics Issues in ADP では、ADP を動かすためのデータ分析上の問題を扱う。価値関数や方策を近似するには、状態、決定、外生情報、報酬、遷移のデータが必要である。実データだけでは不足する場合、シミュレーションで学習データを生成することもある。supervised learning は、入力と正解ラベルの対応から予測モデルを学ぶ方法である。VFA では、特徴量を入力し、シミュレーションや DP で得た価値推定をラベルとして学習できる。unsupervised learning は、ラベルなしデータからクラスや低次元構造を見つける。状態集約や需要パターン分類で役立つ。

Feature selection は、既存の候補特徴から重要なものを選ぶことである。例えば車両位置、残り容量、残り時間、遅延注文数のうち、将来価値の説明に効くものを選ぶ。Dimensionality reduction は、既存特徴を組み合わせで新しい低次元表現を作ることである。PCA やオートエンコーダのような方法が該当する。

外生情報の生成では、過去データから分布を推定し、乱数で将来シナリオを生成する。旅行時間、需要発生、サービス時間などをサンプリングすることで、Rollout や VFA 学習に必要な未来パスを作る。ただし、分布仮定が間違っていると学習された方策も現実合わない。

試験では、ADP を単なる最適化手法としてではなく、データ分析・特徴量設計・学習・シミュレーションが組み合わさったシステムとして説明する。特に feature selection と dimensionality reduction の違いは頻出であり、例を添えて説明する。

確認問題と解答

- L09-S008: 「Generating stochastic transition from distribution」の概念を、定義・具体例・モデル上の意味の順に説明せよ。**
定義としては、ADP ではデータ生成、特徴量、学習方法、評価が政策品質を左右する。具体例では、配送・在庫・フードデリバリーのような現実問題を用い、状態、決定、外生情報、報酬、または情報モデル/意思決定モデルのどこに対応するかを明示する。モデル上の意味として、この概念が目的関数、制約、状態表現、将来価値、または方策選択にどのような影響を与えるかを書く。試験では、用語だけを列挙せず、入力データから意思決定、さらに現実の実装へつながる流れを文章で示すことが重要である。
- L09-S008: このスライドの考え方を、講義全体の DDDM プロセスの中に位置づけよ。**
DDDM プロセスでは、現実世界のデータを集約して情報モデルを作り、意思決定モデルまたは方策で行動を選び、実装後に結果を観測して次の状態へ進む。このスライドの概念は、そのどこか一部だけではなく、データ表現、意思決定、将来不確実性、計算可能性のいずれかに関わる。答えでは、まずこの概念がどの段階に属するかを述べ、次に他の段階へどう影響するかを書く。例えば価値関数なら将来価値を現在決定へ戻す役割、FIFO なら旅行時間情報モデルの整合性を保証する役割、CFA なら目的関数を調整して将来に良い行動を誘導する役割である。

Generating stochastic transition for distribution


- Apply inversion method if random variable comes with an invertible cumulative form F^{-1}

- Inversion of $F(x)$ for exponential distribution

$$\begin{aligned} y &= 1 - e^{-\theta x} \\ e^{-\theta x} &= 1 - y \\ -\theta x &= \ln(1 - y) \\ x &= -\frac{\ln(1 - y)}{\theta} \end{aligned}$$

- Generate random variable $X = F^{-1}(I \sim U(0, 1))$

- A sample from uniform distribution $U(0,1)$ is transposed into an exponentially dist. sample



日本語訳

- Generating 確率的遷移 for 分布
- <https://medium.com/@m.pierini/generation-of-a-random-variable-with-the-inversion-method-4ea99e12569a> (この用語は講義スライド上の専門語として扱う)
- Apply inversion method if random variable comes (この用語は講義スライド上の専門語として扱う)
- with an invertible cumulative form □ □1 (この用語は講義スライド上の専門語として扱う)
- Inversion of □ □ for exponential 分布
- Generate random variable (この用語は講義スライド上の専門語として扱う)
- A sample from uniform 分布 □ 0,1 is transposed into an exponentially dist. sample

試験対策ポイント

- ADP ではデータ生成、特微量、学習方法、評価が政策品質を左右する。
- feature selection と dimensionality reduction を区別する。

解説

このページでは「Generating stochastic transition for distribution」を理解する。スライド上の表現は短いですが、試験では定義、具体例、モデル上の意味、手法の限界まで説明できる必要がある。

Analytics Issues in ADP では、ADP を動かすためのデータ分析上の問題を扱う。価値関数や方策を近似するには、状態、決定、外生情報、報酬、遷移のデータが必要である。実データだけでは不足する場合、シミュレーションで学習データを生成することもある。

supervised learning は、入力と正解ラベルの対応から予測モデルを学ぶ方法である。VFA では、特微量を入力し、シミュレーションや DP で得た価値推定をラベルとして学習できる。unsupervised learning は、ラベルなしデータからクラスや低次元構造を見つける。状態集約や需要パターン分類で役立つ。

Feature selection は、既存の候補特徴から重要なものを選ぶことである。例えば車両位置、残り容量、残り時間、遅延注文数のうち、将来価値の説明に効くものを選ぶ。Dimensionality reduction は、既存特徴を組み合わせで新しい低次元表現を作ることである。PCA やオートエンコーダのような方法が該当する。

外生情報の生成では、過去データから分布を推定し、乱数で将来シナリオを生成する。旅行時間、需要発生、サービス時間などをサンプリングすることで、Rollout や VFA 学習に必要な未来パスを作る。ただし、分布仮定が間違っていると学習された方策も現実合わない。

試験では、ADP を単なる最適化手法としてではなく、データ分析・特微量設計・学習・シミュレーションが組み合わさったシステムとして説明する。特に feature selection と dimensionality reduction の違いは頻出であり、例を添えて説明する。

確認問題と解答

- L09-S009: 「Generating stochastic transition for distribution」の概念を、定義・具体例・モデル上の意味の順に説明せよ。**
定義としては、ADP ではデータ生成、特微量、学習方法、評価が政策品質を左右する。具体例では、配送・在庫・フードデリバリーのような現実問題を扱い、状態、決定、外生情報、報酬、または情報モデル/意思決定モデルのどこに対応するかを明示する。モデル上の意味として、この概念が目的関数、制約、状態表現、将来価値、または方策選択にどのような影響を与えるかを書く。試験では、用語だけを列挙せず、入力データから意思決定、さらに現実の実装へつながる流れを文章で示すことが重要である。
- L09-S009: このスライドの考え方を、講義全体の DDDM プロセスの中に位置づけよ。**
DDDМ プロセスでは、現実世界のデータを集約して情報モデルを作り、意思決定モデルまたは方策で行動を選び、実装後に結果を観測して次の状態へ進む。このスライドの概念は、そのどこか一部だけではなく、データ表現、意思決定、将来不確実性、計算可能性のいずれかに関わる。答えでは、まずこの概念がどの段階に属するかを述べ、次に他の段階へどう影響するかを書く。例えば価値関数なら将来価値を現在決定へ戻す役割、FIFO なら旅行時間情報モデルの整合性を保証する役割、CFA なら目的関数を調整して将来に良い行動を誘導する役割である。

Generating stochastic transition from observations

- A logistics problem is considered, which is to be solved with the help of sequential decision making. The problem extends over many decision points at which new commodities appear
- Commodities are to be delivered to their destination on time in a complex network.
- For this purpose, a simulation introduces commodities over time. A commodity has start location, a destination, a delivery time and a weight.
- All these features cannot simply be drawn from distributions.
- Since there is access to historic logistics data, new data can be generated for our problem by drawing samples from the historic pool of commodities at random



解説

このページでは「Generating stochastic transition from observations」を理解する。スライド上の表現は短い、試験では定義、具体例、モデル上の意味、手法の限界まで説明できる必要がある。

Analytics Issues in ADP では、ADP を動かすためのデータ分析上の問題を扱う。価値関数や方策を近似するには、状態、決定、外生情報、報酬、遷移のデータが必要である。実データだけでは不足する場合、シミュレーションで学習データを生成することもある。supervised learning は、入力と正解ラベルの対応から予測モデルを学ぶ方法である。VFA では、特徴量を入力し、シミュレーションや DP で得た価値推定をラベルとして学習できる。unsupervised learning は、ラベルなしデータからクラスターや低次元構造を見つける。状態集約や需要パターン分類で役立つ。

Feature selection は、既存の候補特徴から重要なものを選ぶことである。例えば車両位置、残り容量、残り時間、遅延注文数のうち、将来価値の説明に効くものを選ぶ。Dimensionality reduction は、既存特徴を組み合わせで新しい低次元表現を作ることである。PCA やオートエンコーダのような方法が該当する。

外生情報の生成では、過去データから分布を推定し、乱数で将来シナリオを生成する。旅行時間、需要発生、サービス時間などをサンプリングすることで、Rollout や VFA 学習に必要な未来パスを作る。ただし、分布仮定が間違っていると学習された方策も現実合わない。

試験では、ADP を単なる最適化手法としてではなく、データ分析・特徴量設計・学習・シミュレーションが組み合わさったシステムとして説明する。特に feature selection と dimensionality reduction の違いは頻出であり、例を添えて説明する。

確認問題と解答

1. **L09-S010: 「Generating stochastic transition from observations」の概念を、定義・具体例・モデル上の意味の順に説明せよ。**
定義としては、ADP ではデータ生成、特徴量、学習方法、評価が政策品質を左右する。。具体例では、配送・在庫・フードデリバリーのような現実問題を扱い、状態、決定、外生情報、報酬、または情報モデル/意思決定モデルのどこに対応するかを明示する。モデル上の意味として、この概念が目的関数、制約、状態表現、将来価値、または方策選択にどのような影響を与えるかを書く。試験では、用語だけを列挙せず、入力データから意思決定、さらに現実の実装へつながる流れを文章で示すことが重要である。
2. **L09-S010: このスライドの考え方を、講義全体の DDDM プロセスの中に位置づけよ。**
DDDM プロセスでは、現実世界のデータを集約して情報モデルを作り、意思決定モデルまたは方策で行動を選び、実装後に結果を観測して次の状態へ進む。このスライドの概念は、そのどこか一部だけではなく、データ表現、意思決定、将来不確実性、計算可能性のいずれかに関わる。答案では、まずこの概念がどの段階に属するかを述べ、次に他の段階へどう影響するかを書く。例えば価値関数なら将来価値を現在決定へ戻す役割、FIFO なら旅行時間情報モデルの整合性を保証する役割、CFA なら目的関数を調整して将来に良い行動を誘導する役割である。

日本語訳

- Generating 確率的遷移 from observations
- □ A logistics problem is considered, which is to be solved with the help of sequential (この用語は講義スライド上の専門語として扱う)
- 決定 making. The problem extends over many 決定 points at which new
- commodities appear (この用語は講義スライド上の専門語として扱う)
- □ Commodities are to be delivered to their destination on time in a complex network. (この用語は講義スライド上の専門語として扱う)
- □ For this purpose, a シミュレーション introduces commodities over time. A commodity has a
- start location, a destination, a delivery time and a weight. (この用語は講義スライド上の専門語として扱う)
- □ All these features cannot simply be drawn from 分布 s.
- □ Since there is access to historic logistics data, new data can be generated for our (この用語は講義スライド上の専門語として扱う)

試験対策ポイント


- ADP ではデータ生成、特徴量、学習方法、評価が政策品質を左右する。
- feature selection と dimensionality reduction を区別する。

Choosing the number of commodities

- The first step is to decide how many new commodities will appear within each stochastic transition.
- In the literature, this number is usually determined using a discrete Poisson distribution (suggesting # of independent events occurring)

$$P_{\theta}(k) = \frac{\theta^k}{k!} e^{-\theta}$$

- Parameter θ determines the expected #, k denotes realizations.
- The CDF is built by summing up n probabilities $F_{\theta}(n) = \sum_{k=0}^n P_{\theta}(k)$
- Since the CDF is not invertible, draw x : $F_{\theta}(x) \leq U(0,1) \leq F_{\theta}(x+1)$



日本語訳

- Choosing the number of commodities $\theta = 1$ (この用語は講義スライド上の専門語として扱う)
- $\theta = 5$
- $\theta = 9$
- The first step is to decide how many new commodities will appear (この用語は講義スライド上の専門語として扱う)
- within each 確率的遷移.
- In the literature, this number is usually determined using a discrete (この用語は講義スライド上の専門語として扱う)
- Poisson 分布 (suggesting # of independent events occurring)
- θ □ θ
- θ □ = □

試験対策ポイント

- ADP ではデータ生成、特徴量、学習方法、評価が政策品質を左右する。
- feature selection と dimensionality reduction を区別する。

解説

このページでは「Choosing the number of commodities $\theta = 1$ 」を理解する。スライド上の表現は短いが、試験では定義、具体例、モデル上の意味、手法の限界まで説明できる必要がある。

Analytics Issues in ADP では、ADP を動かすためのデータ分析上の問題を扱う。価値関数や方策を近似するには、状態、決定、外生情報、報酬、遷移のデータが必要である。実データだけでは不足する場合、シミュレーションで学習データを生成することもある。supervised learning は、入力と正解ラベルの対応から予測モデルを学ぶ方法である。VFA では、特徴量を入力し、シミュレーションや DP で得た価値推定をラベルとして学習できる。unsupervised learning は、ラベルなしデータからクラスタや低次元構造を見つける。状態集約や需要パターン分類で役立つ。

Feature selection は、既存の候補特徴から重要なものを選ぶことである。例えば車両位置、残り容量、残り時間、遅延注文数のうち、将来価値の説明に効くものを選ぶ。Dimensionality reduction は、既存特徴を組み合わせて新しい低次元表現を作ることである。PCA やオートエンコーダのような方法が該当する。

外生情報の生成では、過去データから分布を推定し、乱数で将来シナリオを生成する。旅行時間、需要発生、サービス時間などをサンプリングすることで、Rollout や VFA 学習に必要な未来パスを作る。ただし、分布仮定が間違っていると学習された方策も現実合わない。

試験では、ADP を単なる最適化手法としてではなく、データ分析・特徴量設計・学習・シミュレーションが組み合わさったシステムとして説明する。特に feature selection と dimensionality reduction の違いは頻出であり、例を添えて説明する。

確認問題と解答

- L09-S011: 「Choosing the number of commodities $\theta = 1$ 」の概念を、定義・具体例・モデル上の意味の順に説明せよ。**

定義としては、ADP ではデータ生成、特徴量、学習方法、評価が政策品質を左右する。。具体例では、配送・在庫・フードデリバリーのような現実問題を扱い、状態、決定、外生情報、報酬、または情報モデル/意思決定モデルのどこに対応するかを明示する。モデル上の意味として、この概念が目的関数、制約、状態表現、将来価値、または方策選択にどのような影響を与えるかを書く。試験では、用語だけを列挙せず、入力データから意思決定、さらに現実の実装へつながる流れを文章で示すことが重要である。

- L09-S011: このスライドの考え方を、講義全体の DDDM プロセスの中に位置づけよ。**

DDDM プロセスでは、現実世界のデータを集約して情報モデルを作り、意思決定モデルまたは方策で行動を選び、実装後に結果を観測して次の状態へ進む。このスライドの概念は、そのどこか一部だけではなく、データ表現、意思決定、将来不確実性、計算可能性のいずれかに関わる。答案では、まずこの概念がどの段階に属するかを述べ、次に他の段階へどう影響するかを書く。例えば価値関数なら将来価値を現在決定へ戻す役割、FIFO なら旅行時間情報モデルの整合性を保証する役割、CFA なら目的関数を調整して将来に良い行動を誘導する役割である。

Choosing the commodities

- The second step is to select the commodities that appear in the respective transitions.
- As many commodities (as previously specified by the Poisson distribution) are drawn from the pool of all available commodities at each decision time.
- Since the (unknown) underlying distribution are already in the data, the selection can be made using a discrete uniform distribution.
- With this, each commodity x has the same probability of being selected from an array of n commodities ranging from 0 to $n - 1$: $x = \lfloor U(0,1) * n \rfloor$
- In this way, a data set can be compiled for a sequential decision process.



Data Driven Decision Making | Lecture 9 – Analytics Issues in ADP | Page 12

© Prof. Dr. Dirk C. Mattfeld



日本語訳

- Choosing the commodities（この用語は講義スライド上の専門語として扱う）
- □ The second step is to select the commodities that appear in the respective 遷移 s.
- □ As many commodities (as previously specified by the Poisson 分布) are drawn from the pool of all available commodities at each 決定 time.
- □ Since the (unknown) underlying 分布 are already in the data, the selection can be made using a discrete uniform 分布.
- □ With this, each commodity □ has the same probability of being selected from an array of □（この用語は講義スライド上の専門語として扱う）
- commodities ranging from 0 to □ □ 1: □ = □□ 0,1 □ □□（この用語は講義スライド上の専門語として扱う）
- □ In this way, a data set can be compiled for a sequential 決定 process.

試験対策ポイント

- ADP ではデータ生成、特徴量、学習方法、評価が政策品質を左右する。
- feature selection と dimensionality reduction を区別する。

解説

このページでは「Choosing the commodities」を理解する。スライド上の表現は短いが、試験では定義、具体例、モデル上の意味、手法の限界まで説明できる必要がある。

Analytics Issues in ADP では、ADP を動かすためのデータ分析上の問題を扱う。価値関数や方策を近似するには、状態、決定、外生情報、報酬、遷移のデータが必要である。実データだけでは不足する場合、シミュレーションで学習データを生成することもある。supervised learning は、入力と正解ラベルの対応から予測モデルを学ぶ方法である。VFA では、特徴量を入力し、シミュレーションや DP で得た価値推定をラベルとして学習できる。unsupervised learning は、ラベルなしデータからクラスや低次元構造を見つける。状態集約や需要パターン分類で役立つ。

Feature selection は、既存の候補特徴から重要なものを選ぶことである。例えば車両位置、残り容量、残り時間、遅延注文数のうち、将来価値の説明に効くものを選ぶ。Dimensionality reduction は、既存特徴を組み合わせて新しい低次元表現を作ることである。PCA やオートエンコーダのような方法が該当する。

外生情報の生成では、過去データから分布を推定し、乱数で将来シナリオを生成する。旅行時間、需要発生、サービス時間などをサンプリングすることで、Rollout や VFA 学習に必要な未来パスを作る。ただし、分布仮定が間違っていると学習された方策も現実合わない。

試験では、ADP を単なる最適化手法としてではなく、データ分析・特徴量設計・学習・シミュレーションが組み合わさったシステムとして説明する。特に feature selection と dimensionality reduction の違いは頻出であり、例を添えて説明する。

確認問題と解答

1. **L09-S012: 「Choosing the commodities」の概念を、定義・具体例・モデル上の意味の順に説明せよ。**
定義としては、ADP ではデータ生成、特徴量、学習方法、評価が政策品質を左右する。。具体例では、配送・在庫・フードデリバリーのような現実問題を用い、状態、決定、外生情報、報酬、または情報モデル/意思決定モデルのどこに対応するかを明示する。モデル上の意味として、この概念が目的関数、制約、状態表現、将来価値、または方策選択にどのような影響を与えるかを書く。試験では、用語だけを列挙せず、入力データから意思決定、さらに現実の実装へつながる流れを文章で示すことが重要である。
2. **L09-S012: このスライドの考え方を、講義全体の DDDM プロセスの中に位置づけよ。**
DDDM プロセスでは、現実世界のデータを集約して情報モデルを作り、意思決定モデルまたは方策で行動を選び、実装後に結果を観測して次の状態へ進む。このスライドの概念は、そのどこか一部だけではなく、データ表現、意思決定、将来不確実性、計算可能性のいずれかに関わる。答案では、まずこの概念がどの段階に属するかを述べ、次に他の段階へどう影響するかを書く。例えば価値関数なら将来価値を現在決定へ戻す役割、FIFO なら旅行時間情報モデルの整合性を保証する役割、CFA なら目的関数を調整して将来に良い行動を誘導する役割である。

Two issues with generating stochastic transitions

- Correlation
 - Random variables are not independent but follow some correlation
 - Correlation (due to causation) can appear time and/or space relation
 - For instance, a congestion on a road will cause a congestion on a parallel road
 - Zhaoxia Guo, Stein W. Wallace, Michal Kaut (2019) Vehicle Routing with Space- and Time-Correlated Stochastic Travel Times: Evaluating the Objective Function. INFORMS Journal on Computing 31(4):654-670
- Outlier
 - A distribution approximated from observations include historic peculiarities
 - In terms of a predictive model (what will happen?), overfitting is a topic
 - A predictive model comes with two objectives (accuracy and reduction of variance)
 - See Shmueli, G., & Koppius, O.R. (2011) Predictive Analytics in Information Systems Research. MIS Quarterly, 35(3), 553–572



Data Driven Decision Making | Lecture 9 – Analytics Issues in ADP | Page 13



日本語訳

- Two issues with generating 確率的遷移 s
- Correlation (この用語は講義スライド上の専門語として扱う)
- Random variables are not independent but follow some correlation (この用語は講義スライド上の専門語として扱う)
- Correlation (due to causation) can appear time and/or space relation (この用語は講義スライド上の専門語として扱う)
- For instance, a congestion on a road will cause a congestion on a parallel road (この用語は講義スライド上の専門語として扱う)
- Zhaoxia Guo, Stein W. Wallace, Michal Kaut (2019) Vehicle Routing with Space- and Time-Correlated Stochastic (この用語は講義スライド上の専門語として扱う)
- 旅行時間: Evaluating the 目的 Function. INFORMS Journal on Computing 31(4):654-670
- Outlier (この用語は講義スライド上の専門語として扱う)
- A 分布 approximated from observations include historic peculiarities

試験対策ポイント

- ADP ではデータ生成、特微量、学習方法、評価が政策品質を左右する。
- feature selection と dimensionality reduction を区別する。

解説

このページでは「Two issues with generating stochastic transitions」を理解する。スライド上の表現は短い、試験では定義、具体例、モデル上の意味、手法の限界まで説明できる必要がある。

Analytics Issues in ADP では、ADP を動かすためのデータ分析上の問題を扱う。価値関数や方策を近似するには、状態、決定、外生情報、報酬、遷移のデータが必要である。実データだけでは不足する場合、シミュレーションで学習データを生成することもある。supervised learning は、入力と正解ラベルの対応から予測モデルを学ぶ方法である。VFA では、特微量を入力し、シミュレーションや DP で得た価値推定をラベルとして学習できる。unsupervised learning は、ラベルなしデータからクラスターや低次元構造を見つける。状態集約や需要パターン分類で役立つ。

Feature selection は、既存の候補特徴から重要なものを選ぶことである。例えば車両位置、残り容量、残り時間、遅延注文数のうち、将来価値の説明に効くものを選ぶ。Dimensionality reduction は、既存特徴を組み合わせで新しい低次元表現を作ることである。PCA やオートエンコーダのような方法が該当する。


外生情報の生成では、過去データから分布を推定し、乱数で将来シナリオを生成する。旅行時間、需要発生、サービス時間などをサンプリングすることで、Rollout や VFA 学習に必要な未来パスを作る。ただし、分布仮定が間違っていると学習された方策も現実合わない。

試験では、ADP を単なる最適化手法としてではなく、データ分析・特微量設計・学習・シミュレーションが組み合わさったシステムとして説明する。特に feature selection と dimensionality reduction の違いは頻出であり、例を添えて説明する。

確認問題と解答

- L09-S013: 「Two issues with generating stochastic transitions」の概念を、定義・具体例・モデル上の意味の順に説明せよ。**
定義としては、ADP ではデータ生成、特微量、学習方法、評価が政策品質を左右する。。具体例では、配送・在庫・フードデリバリーのような現実問題を扱い、状態、決定、外生情報、報酬、または情報モデル/意思決定モデルのどこに対応するかを明示する。モデル上の意味として、この概念が目的関数、制約、状態表現、将来価値、または方策選択にどのような影響を与えるかを書く。試験では、用語だけを列挙せず、入力データから意思決定、さらに現実の実装へつながる流れを文章で示すことが重要である。
- L09-S013: このスライドの考え方を、講義全体の DDDM プロセスの中に位置づけよ。**
DDDM プロセスでは、現実世界のデータを集約して情報モデルを作り、意思決定モデルまたは方策で行動を選び、実装後に結果を観測して次の状態へ進む。このスライドの概念は、そのどこか一部だけではなく、データ表現、意思決定、将来不確実性、計算可能性のいずれかに関わる。答えでは、まずこの概念がどの段階に属するかを述べ、次に他の段階へどう影響するかを書く。例えば価値関数なら将来価値を現在決定へ戻す役割、FIFO なら旅行時間情報モデルの整合性を保証する役割、CFA なら目的関数を調整して将来に良い行動を誘導する役割である。

Feature Engineering



日本語訳

- Feature Engineering（この用語は講義スライド上の専門語として扱う）

試験対策ポイント

- ADP ではデータ生成、特徴量、学習方法、評価が政策品質を左右する。
- feature selection と dimensionality reduction を区別する。

解説

このページでは「Feature Engineering」を理解する。スライド上の表現は短い、試験では定義、具体例、モデル上の意味、手法の限界まで説明できる必要がある。

Analytics Issues in ADP では、ADP を動かすためのデータ分析上の問題を扱う。価値関数や方策を近似するには、状態、決定、外生情報、報酬、遷移のデータが必要である。実データだけでは不足する場合、シミュレーションで学習データを生成することもある。

supervised learning は、入力と正解ラベルの対応から予測モデルを学ぶ方法である。VFA では、特徴量を入力し、シミュレーションや DP で得た価値推定をラベルとして学習できる。unsupervised learning は、ラベルなしデータからクラスや低次元構造を見つける。状態集約や需要パターン分類で役立つ。

Feature selection は、既存の候補特徴から重要なものを選ぶことである。例えば車両位置、残り容量、残り時間、遅延注文数のうち、将来価値の説明に効くものを選ぶ。Dimensionality reduction は、既存特徴を組み合わせで新しい低次元表現を作ることである。PCA やオートエンコーダのような方法が該当する。

外生情報の生成では、過去データから分布を推定し、乱数で将来シナリオを生成する。旅行時間、需要発生、サービス時間などをサンプリングすることで、Rollout や VFA 学習に必要な未来パスを作る。ただし、分布仮定が間違っていると学習された方策も現実合わない。

試験では、ADP を単なる最適化手法としてではなく、データ分析・特徴量設計・学習・シミュレーションが組み合わさったシステムとして説明する。特に feature selection と dimensionality reduction の違いは頻出であり、例を添えて説明する。

確認問題と解答

1. **L09-S014: 「Feature Engineering」の概念を、定義・具体例・モデル上の意味の順に説明せよ。**
定義としては、ADP ではデータ生成、特徴量、学習方法、評価が政策品質を左右する。具体例では、配送・在庫・フードデリバリーのような現実問題を扱い、状態、決定、外生情報、報酬、または情報モデル/意思決定モデルのどこに対応するかを明示する。モデル上の意味として、この概念が目的関数、制約、状態表現、将来価値、または方策選択にどのような影響を与えるかを書く。試験では、用語だけを列挙せず、入力データから意思決定、さらに現実の実装へつながる流れを文章で示すことが重要である。
2. **L09-S014: このスライドの考え方を、講義全体の DDDM プロセスの中に位置づけよ。**
DDDM プロセスでは、現実世界のデータを集約して情報モデルを作り、意思決定モデルまたは方策で行動を選び、実装後に結果を観測して次の状態へ進む。このスライドの概念は、そのどこか一部だけではなく、データ表現、意思決定、将来不確実性、計算可能性のいずれかに関わる。答えでは、まずこの概念がどの段階に属するかを述べ、次に他の段階へどう影響するかを書く。例えば価値関数なら将来価値を現在決定へ戻す役割、FIFO なら旅行時間情報モデルの整合性を保証する役割、CFA なら目的関数を調整して将来に良い行動を誘導する役割である。

Decision Process

- Stochastic and dynamic decision modelling aims at generating an (near) optimal policy
- A policy provides a suitable decision to every state of the state space
- A small state- and decision space helps keeping anticipation computationally tractable
- Space reduction drives out dimensions from consideration (e.g. spatial or time)
- Next to problem specific dimension reduction generic analytics techniques can be applied
- Either important features are selected or the dimensionality of the state space is reduced



Data Driven Decision Making | Lecture 9 – Analytics Issues in ADP | Page 15



日本語訳

- 決定 Process
- □ Stochastic and 動的決定 modelling aims at generating an (near) optimal 方策
- □ A 方策 provides a suitable 決定 to every 状態 of the 状態 space
- □ A small 状態- and 決定 space helps keeping anticipation computationally tractable
- □ Space reduction drives out dimensions from consideration (e.g. spatial or time) (この用語は講義スライド上の専門語として扱う)
- □ Next to problem specific dimension reduction generic analytics techniques can be applied (この用語は講義スライド上の専門語として扱う)
- □ Either important features are selected or the dimensionality of the 状態 space is reduced

試験対策ポイント

- ADP ではデータ生成、特徴量、学習方法、評価が政策品質を左右する。
- feature selection と dimensionality reduction を区別する。

解説

このページでは「Decision Process」を理解する。スライド上の表現は短い、試験では定義、具体例、モデル上の意味、手法の限界まで説明できる必要がある。

Analytics Issues in ADP では、ADP を動かすためのデータ分析上の問題を扱う。価値関数や方策を近似するには、状態、決定、外生情報、報酬、遷移のデータが必要である。実データだけでは不足する場合、シミュレーションで学習データを生成することもある。supervised learning は、入力と正解ラベルの対応から予測モデルを学ぶ方法である。VFA では、特徴量を入力し、シミュレーションや DP で得た価値推定をラベルとして学習できる。unsupervised learning は、ラベルなしデータからクラスや低次元構造を見つける。状態集約や需要パターン分類で役立つ。

Feature selection は、既存の候補特徴から重要なものを選ぶことである。例えば車両位置、残り容量、残り時間、遅延注文数のうち、将来価値の説明に効くものを選ぶ。Dimensionality reduction は、既存特徴を組み合わせて新しい低次元表現を作ることである。PCA やオートエンコーダのような方法が該当する。

外生情報の生成では、過去データから分布を推定し、乱数で将来シナリオを生成する。旅行時間、需要発生、サービス時間などをサンプリングすることで、Rollout や VFA 学習に必要な未来パスを作る。ただし、分布仮定が間違っていると学習された方策も現実合わない。


試験では、ADP を単なる最適化手法としてではなく、データ分析・特徴量設計・学習・シミュレーションが組み合わさったシステムとして説明する。特に feature selection と dimensionality reduction の違いは頻出であり、例を添えて説明する。

確認問題と解答

1. **L09-S015: 「Decision Process」の概念を、定義・具体例・モデル上の意味の順に説明せよ。**
定義としては、ADP ではデータ生成、特徴量、学習方法、評価が政策品質を左右する。。具体例では、配送・在庫・フードデリバリーのような現実問題を扱い、状態、決定、外生情報、報酬、または情報モデル/意思決定モデルのどこに対応するかを明示する。モデル上の意味として、この概念が目的関数、制約、状態表現、将来価値、または方策選択にどのような影響を与えるかを書く。試験では、用語だけを列挙せず、入力データから意思決定、さらに現実の実装へつながる流れを文章で示すことが重要である。
2. **L09-S015: このスライドの考え方を、講義全体の DDDM プロセスの中に位置づけよ。**
DDDM プロセスでは、現実世界のデータを集約して情報モデルを作り、意思決定モデルまたは方策で行動を選び、実装後に結果を観測して次の状態へ進む。このスライドの概念は、そのどこか一部だけではなく、データ表現、意思決定、将来不確実性、計算可能性のいずれかに関わる。答えでは、まずこの概念がどの段階に属するかを述べ、次に他の段階へどう影響するかを書く。例えば価値関数なら将来価値を現在決定へ戻す役割、FIFO なら旅行時間情報モデルの整合性を保証する役割、CFA なら目的関数を調整して将来に良い行動を誘導する役割である。

Feature selection techniques

- Unsupervised: do not incorporate variable
- Supervised: Determine features with strong relations to target variable by statistics
 - Intrinsic: For instance decision trees
 - Wrapper: Start with many features and successively eliminate features
 - Filter: Score features in accordance to relationship between feature and variable



日本語訳

- ・ 特徴選択 techniques
- ・ □ Unsupervised: do not incorporate variable (この用語は講義スライド上の専門語として扱う)
- ・ □ Supervised: Determine features with strong (この用語は講義スライド上の専門語として扱う)
- ・ relations to target variable by statistics (この用語は講義スライド上の専門語として扱う)
- ・ □ Intrinsic: For instance 決定 trees
- ・ □ Wrapper: Start with many features and (この用語は講義スライド上の専門語として扱う)
- ・ successively eliminate features (この用語は講義スライド上の専門語として扱う)
- ・ □ Filter: Score features in accordance to (この用語は講義スライド上の専門語として扱う)
- ・ relationship between feature and variable (この用語は講義スライド上の専門語として扱う)

試験対策ポイント

- ・ ADP ではデータ生成、特徴量、学習方法、評価が政策品質を左右する。
- ・ feature selection と dimensionality reduction を区別する。

解説

このページでは「Feature selection techniques」を理解する。スライド上の表現は短い、試験では定義、具体例、モデル上の意味、手法の限界まで説明できる必要がある。

Analytics Issues in ADP では、ADP を動かすためのデータ分析上の問題を扱う。価値関数や方策を近似するには、状態、決定、外生情報、報酬、遷移のデータが必要である。実データだけでは不足する場合、シミュレーションで学習データを生成することもある。

supervised learning は、入力と正解ラベルの対応から予測モデルを学ぶ方法である。VFA では、特徴量を入力し、シミュレーションや DP で得た価値推定をラベルとして学習できる。unsupervised learning は、ラベルなしデータからクラスや低次元構造を見つける。状態集約や需要パターン分類で役立つ。

Feature selection は、既存の候補特徴から重要なものを選ぶことである。例えば車両位置、残り容量、残り時間、遅延注文数のうち、将来価値の説明に効くものを選ぶ。Dimensionality reduction は、既存特徴を組み合わせで新しい低次元表現を作ることである。PCA やオートエンコーダのような方法が該当する。

外生情報の生成では、過去データから分布を推定し、乱数で将来シナリオを生成する。旅行時間、需要発生、サービス時間などをサンプリングすることで、Rollout や VFA 学習に必要な未来パスを作る。ただし、分布仮定が間違っていると学習された方策も現実合わない。

試験では、ADP を単なる最適化手法としてではなく、データ分析・特徴量設計・学習・シミュレーションが組み合わさったシステムとして説明する。特に feature selection と dimensionality reduction の違いは頻出であり、例を添えて説明する。

確認問題と解答


1. **L09-S016: 「Feature selection techniques」の概念を、定義・具体例・モデル上の意味の順に説明せよ。**
定義としては、ADP ではデータ生成、特徴量、学習方法、評価が政策品質を左右する。。具体例では、配送・在庫・フードデリバリーのような現実問題を扱い、状態、決定、外生情報、報酬、または情報モデル/意思決定モデルのどこに対応するかを明示する。モデル上の意味として、この概念が目的関数、制約、状態表現、将来価値、または方策選択にどのような影響を与えるかを書く。試験では、用語だけを列挙せず、入力データから意思決定、さらに現実の実装へつながる流れを文章で示すことが重要である。
2. **L09-S016: このスライドの考え方を、講義全体の DDDM プロセスの中に位置づけよ。**
DDDM プロセスでは、現実世界のデータを集約して情報モデルを作り、意思決定モデルまたは方策で行動を選び、実装後に結果を観測して次の状態へ進む。このスライドの概念は、そのどこか一部だけではなく、データ表現、意思決定、将来不確実性、計算可能性のいずれかに関わる。答えでは、まずこの概念がどの段階に属するかを述べ、次に他の段階へどう影響するかを書く。例えば価値関数なら将来価値を現在決定へ戻す役割、FIFO なら旅行時間情報モデルの整合性を保証する役割、CFA なら目的関数を調整して将来に良い行動を誘導する役割である。

Filter based feature selection techniques

How to Choose a Feature Selection Method



- Choice by
 - Feature type (input)
 - Variable type (output)
 - Normal distribution (ANOVA)
 - Rank based (Kendall)



解説

このページでは「Filter based feature selection techniques」を理解する。スライド上の表現は短い、試験では定義、具体例、モデル上の意味、手法の限界まで説明できる必要がある。

Analytics Issues in ADP では、ADP を動かすためのデータ分析上の問題を扱う。価値関数や方策を近似するには、状態、決定、外生情報、報酬、遷移のデータが必要である。実データだけでは不足する場合、シミュレーションで学習データを生成することもある。

supervised learning は、入力と正解ラベルの対応から予測モデルを学ぶ方法である。VFA では、特徴量を入力し、シミュレーションや DP で得た価値推定をラベルとして学習できる。unsupervised learning は、ラベルなしデータからクラスや低次元構造を見つける。状態集約や需要パターン分類で役立つ。

Feature selection は、既存の候補特徴から重要なものを選ぶことである。例えば車両位置、残り容量、残り時間、遅延注文数のうち、将来価値の説明に効くものを選ぶ。Dimensionality reduction は、既存特徴を組み合わせで新しい低次元表現を作ることである。PCA やオートエンコーダのような方法が該当する。

外生情報の生成では、過去データから分布を推定し、乱数で将来シナリオを生成する。旅行時間、需要発生、サービス時間などをサンプリングすることで、Rollout や VFA 学習に必要な未来パスを作る。ただし、分布仮定が間違っていると学習された方策も現実合わない。

試験では、ADP を単なる最適化手法としてではなく、データ分析・特徴量設計・学習・シミュレーションが組み合わさったシステムとして説明する。特に feature selection と dimensionality reduction の違いは頻出であり、例を添えて説明する。

確認問題と解答

- L09-S017: 「Filter based feature selection techniques」の概念を、定義・具体例・モデル上の意味の順に説明せよ。**

定義としては、ADP ではデータ生成、特徴量、学習方法、評価が政策品質を左右する。具体例では、配送・在庫・フードデリバリーのような現実問題を扱い、状態、決定、外生情報、報酬、または情報モデル/意思決定モデルのどこに対応するかを明示する。モデル上の意味として、この概念が目的関数、制約、状態表現、将来価値、または方策選択にどのような影響を与えるかを書く。試験では、用語だけを列挙せず、入力データから意思決定、さらに現実の実装へつながる流れを文章で示すことが重要である。

- L09-S017: このスライドの考え方を、講義全体の DDDM プロセスの中に位置づけよ。**

DDDM プロセスでは、現実世界のデータを集約して情報モデルを作り、意思決定モデルまたは方策で行動を選び、実装後に結果を観測して次の状態へ進む。このスライドの概念は、そのどこか一部だけではなく、データ表現、意思決定、将来不確実性、計算可能性のいずれかに関わる。答えでは、まずこの概念がどの段階に属するかを述べ、次に他の段階へどう影響するかを書く。例えば価値関数なら将来価値を現在決定へ戻す役割、FIFO なら旅行時間情報モデルの整合性を保証する役割、CFA なら目的関数を調整して将来に良い行動を誘導する役割である。


日本語訳

- Filter based 特徴選択 techniques
 - Choice by (この用語は講義スライド上の専門語として扱う)
 - Feature type (input) (この用語は講義スライド上の専門語として扱う)
 - Variable type (output) (この用語は講義スライド上の専門語として扱う)
 - Normal 分布 (ANOVA)
 - Rank based (Kendall) (この用語は講義スライド上の専門語として扱う)
- https://machinelearningmastery.com/feature-selection-with-real-and-categorical-data/ (この用語は講義スライド上の専門語として扱う)

試験対策ポイント

- ADP ではデータ生成、特徴量、学習方法、評価が政策品質を左右する。
- feature selection と dimensionality reduction を区別する。

Taxonomy of methods for dimensionality reduction



日本語訳

- Taxonomy of methods for dimensionality reduction (この用語は講義スライド上の専門語として扱う)
- Important properties (この用語は講義スライド上の専門語として扱う)
- Parametrization (この用語は講義スライド上の専門語として扱う)
- Parametric (この用語は講義スライド上の専門語として扱う)
- transformations allow the (この用語は講義スライド上の専門語として扱う)
- mapping of further data (この用語は講義スライド上の専門語として扱う)
- points into the lower- (この用語は講義スライド上の専門語として扱う)
- dimensional space (この用語は講義スライド上の専門語として扱う)
- Linearity (この用語は講義スライド上の専門語として扱う)

試験対策ポイント

- ADP ではデータ生成、特徴量、学習方法、評価が政策品質を左右する。
- feature selection と dimensionality reduction を区別する。

解説

このページでは「Taxonomy of methods for dimensionality reduction」を理解する。スライド上の表現は短い、試験では定義、具体例、モデル上の意味、手法の限界まで説明できる必要がある。

Analytics Issues in ADP では、ADP を動かすためのデータ分析上の問題を扱う。価値関数や方策を近似するには、状態、決定、外生情報、報酬、遷移のデータが必要である。実データだけでは不足する場合、シミュレーションで学習データを生成することもある。

supervised learning は、入力と正解ラベルの対応から予測モデルを学ぶ方法である。VFA では、特徴量を入力し、シミュレーションや DP で得た価値推定をラベルとして学習できる。unsupervised learning は、ラベルなしデータからクラスターや低次元構造を見つける。状態集約や需要パターン分類で役立つ。

Feature selection は、既存の候補特徴から重要なものを選ぶことである。例えば車両位置、残り容量、残り時間、遅延注文数のうち、将来価値の説明に効くものを選ぶ。Dimensionality reduction は、既存特徴を組み合わせて新しい低次元表現を作ることである。PCA やオートエンコーダのような方法が該当する。

外生情報の生成では、過去データから分布を推定し、乱数で将来シナリオを生成する。旅行時間、需要発生、サービス時間などをサンプリングすることで、Rollout や VFA 学習に必要な未来パスを作る。ただし、分布仮定が間違っていると学習された方策も現実合わない。

試験では、ADP を単なる最適化手法としてではなく、データ分析・特徴量設計・学習・シミュレーションが組み合わさったシステムとして説明する。特に feature selection と dimensionality reduction の違いは頻出であり、例を添えて説明する。

確認問題と解答

1. **L09-S018: 「Taxonomy of methods for dimensionality reduction」の概念を、定義・具体例・モデル上の意味の順に説明せよ。**
定義としては、ADP ではデータ生成、特徴量、学習方法、評価が政策品質を左右する。。具体例では、配送・在庫・フードデリバリーのような現実問題を用い、状態、決定、外生情報、報酬、または情報モデル/意思決定モデルのどこに対応するかを明示する。モデル上の意味として、この概念が目的関数、制約、状態表現、将来価値、または方策選択にどのような影響を与えるかを書く。試験では、用語だけを列挙せず、入力データから意思決定、さらに現実の実装へつながる流れを文章で示すことが重要である。
2. **L09-S018: このスライドの考え方を、講義全体の DDDM プロセスの中に位置づけよ。**
DDDM プロセスでは、現実世界のデータを集約して情報モデルを作り、意思決定モデルまたは方策で行動を選び、実装後に結果を観測して次の状態へ進む。このスライドの概念は、そのどこか一部だけではなく、データ表現、意思決定、将来不確実性、計算可能性のいずれかに関わる。答えでは、まずこの概念がどの段階に属するかを述べ、次に他の段階へどう影響するかを書く。例えば価値関数なら将来価値を現在決定へ戻す役割、FIFO なら旅行時間情報モデルの整合性を保証する役割、CFA なら目的関数を調整して将来に良い行動を誘導する役割である。

Possible Candidates for Reduction of Dimensionality

Van der Maaten et al. (2009)

Review paper testing dimensionality reduction methods on artificial and real datasets

Method	Description	Graphik
PCA	- Lower-dimensional representation maximizing the variance of the data sample - Linear transformation - Parametric mapping	
Auto-encoder	- Lower-dimensional representation minimizing the minimal squared error of the reconstructed input - Non-linear transformation - Parametric mapping	

Accelerated learning
With lowered dimensionality the combinatoric of states decreases which allows for more visits per state

Reduced performance
As dimensionality reduction is related to loss of information the performance in convergence is reduced

This and following slides: Dissertation of Julius Heitmann (2023)

© Prof. Dr. Dirk C. Mattfeld

Decision Support Institute für Wirtschaftsinformatik

日本語訳

- Possible Candidates for Reduction of Dimensionality（この用語は講義スライド上の専門語として扱う）
- Van der Maaten Method Description Graphik（この用語は講義スライド上の専門語として扱う）
- et al. (2009)
- □ Lower-dimensional（この用語は講義スライド上の専門語として扱う）
- representation Accelerated learning（この用語は講義スライド上の専門語として扱う）
- maximizing the variance With lowered（この用語は講義スライド上の専門語として扱う）
- PCA dimensionality the（この用語は講義スライド上の専門語として扱う）
- of the data sample（この用語は講義スライド上の専門語として扱う）
- + combinatoric of 状態 s

試験対策ポイント

- ADP ではデータ生成、特徴量、学習方法、評価が政策品質を左右する。
- feature selection と dimensionality reduction を区別する。

解説

このページでは「Possible Candidates for Reduction of Dimensionality」を理解する。スライド上の表現は短いが、試験では定義、具体例、モデル上の意味、手法の限界まで説明できる必要がある。

Analytics Issues in ADP では、ADP を動かすためのデータ分析上の問題を扱う。価値関数や方策を近似するには、状態、決定、外生情報、報酬、遷移のデータが必要である。実データだけでは不足する場合、シミュレーションで学習データを生成することもある。

supervised learning は、入力と正解ラベルの対応から予測モデルを学ぶ方法である。VFA では、特徴量を入力し、シミュレーションや DP で得た価値推定をラベルとして学習できる。unsupervised learning は、ラベルなしデータからクラスタや低次元構造を見つける。状態集約や需要パターン分類で役立つ。

Feature selection は、既存の候補特徴から重要なものを選ぶことである。例えば車両位置、残り容量、残り時間、遅延注文数のうち、将来価値の説明に効くものを選ぶ。Dimensionality reduction は、既存特徴を組み合わせて新しい低次元表現を作ることである。PCA やオートエンコーダのような方法が該当する。


外生情報の生成では、過去データから分布を推定し、乱数で将来シナリオを生成する。旅行時間、需要発生、サービス時間などをサンプリングすることで、Rollout や VFA 学習に必要な未来パスを作る。ただし、分布仮定が間違っていると学習された方策も現実合わない。

試験では、ADP を単なる最適化手法としてではなく、データ分析・特徴量設計・学習・シミュレーションが組み合わさったシステムとして説明する。特に feature selection と dimensionality reduction の違いは頻出であり、例を添えて説明する。

確認問題と解答

1. **L09-S019: 「Possible Candidates for Reduction of Dimensionality」の概念を、定義・具体例・モデル上の意味の順に説明せよ。**
定義としては、ADP ではデータ生成、特徴量、学習方法、評価が政策品質を左右する。。具体例では、配送・在庫・フードデリバリーのような現実問題を用い、状態、決定、外生情報、報酬、または情報モデル/意思決定モデルのどこに対応するかを明示する。モデル上の意味として、この概念が目的関数、制約、状態表現、将来価値、または方策選択にどのような影響を与えるかを書く。試験では、用語だけを列挙せず、入力データから意思決定、さらに現実の実装へつながる流れを文章で示すことが重要である。
2. **L09-S019: このスライドの考え方を、講義全体の DDDM プロセスの中に位置づけよ。**
DDDМ プロセスでは、現実世界のデータを集約して情報モデルを作り、意思決定モデルまたは方策で行動を選び、実装後に結果を観測して次の状態へ進む。このスライドの概念は、そのどこか一部だけではなく、データ表現、意思決定、将来不確実性、計算可能性のいずれかに関わる。答えでは、まずこの概念がどの段階に属するかを述べ、次に他の段階へどう影響するかを書く。例えば価値関数なら将来価値を現在決定へ戻す役割、FIFO なら旅行時間情報モデルの整合性を保証する役割、CFA なら目的関数を調整して将来に良い行動を誘導する役割である。

Performance on a demand responsive taxi problem



日本語訳

- Performance on a demand responsive taxi problem（この用語は講義スライド上の専門語として扱う）
- PCA and AE learn (and perform) better at start 状態 representation Relative performance Accepted requests
- High-dimensional 状態 104.3% 30.7
- PCA 状態 103.1% 28.1
- In later iterations the high-dim model catches up Autoencoder 状態 102.0% 31.3
- Aggregated 状態 101.5% 29.8
- Myopic reference 100.0% 30.6（この用語は講義スライド上の専門語として扱う）

試験対策ポイント

- ADP ではデータ生成、特徴量、学習方法、評価が政策品質を左右する。
- feature selection と dimensionality reduction を区別する。

解説

このページでは「Performance on a demand responsive taxi problem」を理解する。スライド上の表現は短いが、試験では定義、具体例、モデル上の意味、手法の限界まで説明できる必要がある。

Analytics Issues in ADP では、ADP を動かすためのデータ分析上の問題を扱う。価値関数や方策を近似するには、状態、決定、外生情報、報酬、遷移のデータが必要である。実データだけでは不足する場合、シミュレーションで学習データを生成することもある。

supervised learning は、入力と正解ラベルの対応から予測モデルを学ぶ方法である。VFA では、特徴量を入力し、シミュレーションや DP で得た価値推定をラベルとして学習できる。unsupervised learning は、ラベルなしデータからクラスタや低次元構造を見つける。状態集約や需要パターン分類で役立つ。

Feature selection は、既存の候補特徴から重要なものを選ぶことである。例えば車両位置、残り容量、残り時間、遅延注文数のうち、将来価値の説明に効くものを選ぶ。Dimensionality reduction は、既存特徴を組み合わせて新しい低次元表現を作ることである。PCA やオートエンコーダのような方法が該当する。


外生情報の生成では、過去データから分布を推定し、乱数で将来シナリオを生成する。旅行時間、需要発生、サービス時間などをサンプリングすることで、Rollout や VFA 学習に必要な未来パスを作る。ただし、分布仮定が間違っていると学習された方策も現実合わない。

試験では、ADP を単なる最適化手法としてではなく、データ分析・特徴量設計・学習・シミュレーションが組み合わさったシステムとして説明する。特に feature selection と dimensionality reduction の違いは頻出であり、例を添えて説明する。

確認問題と解答

- L09-S020: 「Performance on a demand responsive taxi problem」の概念を、定義・具体例・モデル上の意味の順に説明せよ。**
定義としては、ADP ではデータ生成、特徴量、学習方法、評価が政策品質を左右する。。具体例では、配送・在庫・フードデリバリーのような現実問題を扱い、状態、決定、外生情報、報酬、または情報モデル/意思決定モデルのどこに対応するかを明示する。モデル上の意味として、この概念が目的関数、制約、状態表現、将来価値、または方策選択にどのような影響を与えるかを書く。試験では、用語だけを列挙せず、入力データから意思決定、さらに現実の実装へつながる流れを文章で示すことが重要である。
- L09-S020: このスライドの考え方を、講義全体の DDDM プロセスの中に位置づけよ。**
DDDM プロセスでは、現実世界のデータを集約して情報モデルを作り、意思決定モデルまたは方策で行動を選び、実装後に結果を観測して次の状態へ進む。このスライドの概念は、そのどこか一部だけではなく、データ表現、意思決定、将来不確実性、計算可能性のいずれかに関わる。答えでは、まずこの概念がどの段階に属するかを述べ、次に他の段階へどう影響するかを書く。例えば価値関数なら将来価値を現在決定へ戻す役割、FIFO なら旅行時間情報モデルの整合性を保証する役割、CFA なら目的関数を調整して将来に良い行動を誘導する役割である。

Endogenous information



日本語訳

- Endogenous information (この用語は講義スライド上の専門語として扱う)
- Endogenous Information (この用語は講義スライド上の専門語として扱う)

試験対策ポイント

- ADP ではデータ生成、特徴量、学習方法、評価が政策品質を左右する。
- feature selection と dimensionality reduction を区別する。

解説

このページでは「Endogenous information」を理解する。スライド上の表現は短いですが、試験では定義、具体例、モデル上の意味、手法の限界まで説明できる必要がある。

Analytics Issues in ADP では、ADP を動かすためのデータ分析上の問題を扱う。価値関数や方策を近似するには、状態、決定、外生情報、報酬、遷移のデータが必要である。実データだけでは不足する場合、シミュレーションで学習データを生成することもある。

supervised learning は、入力と正解ラベルの対応から予測モデルを学ぶ方法である。VFA では、特徴量を入力し、シミュレーションや DP で得た価値推定をラベルとして学習できる。unsupervised learning は、ラベルなしデータからクラスや低次元構造を見つける。状態集約や需要パターン分類で役立つ。

Feature selection は、既存の候補特徴から重要なものを選ぶことである。例えば車両位置、残り容量、残り時間、遅延注文数のうち、将来価値の説明に効くものを選ぶ。Dimensionality reduction は、既存特徴を組み合わせで新しい低次元表現を作ることである。PCA やオートエンコーダのような方法が該当する。

外生情報の生成では、過去データから分布を推定し、乱数で将来シナリオを生成する。旅行時間、需要発生、サービス時間などをサンプリングすることで、Rollout や VFA 学習に必要な未来パスを作る。ただし、分布仮定が間違っていると学習された方策も現実合わない。

試験では、ADP を単なる最適化手法としてではなく、データ分析・特徴量設計・学習・シミュレーションが組み合わさったシステムとして説明する。特に feature selection と dimensionality reduction の違いは頻出であり、例を添えて説明する。

確認問題と解答

1. **L09-S021: 「Endogenous information」の概念を、定義・具体例・モデル上の意味の順に説明せよ。**

定義としては、ADP ではデータ生成、特徴量、学習方法、評価が政策品質を左右する。具体例では、配送・在庫・フードデリバリーのような現実問題を扱い、状態、決定、外生情報、報酬、または情報モデル/意思決定モデルのどこに対応するかを明示する。モデル上の意味として、この概念が目的関数、制約、状態表現、将来価値、または方策選択にどのような影響を与えるかを書く。試験では、用語だけを列挙せず、入力データから意思決定、さらに現実の実装へつながる流れを文章で示すことが重要である。

2. **L09-S021: このスライドの考え方を、講義全体の DDDM プロセスの中に位置づけよ。**

DDDM プロセスでは、現実世界のデータを集約して情報モデルを作り、意思決定モデルまたは方策で行動を選び、実装後に結果を観測して次の状態へ進む。このスライドの概念は、そのどこか一部だけではなく、データ表現、意思決定、将来不確実性、計算可能性のいずれかに関わる。答えでは、まずこの概念がどの段階に属するかを述べ、次に他の段階へどう影響するかを書く。例えば価値関数なら将来価値を現在決定へ戻す役割、FIFO なら旅行時間情報モデルの整合性を保証する役割、CFA なら目的関数を調整して将来に良い行動を誘導する役割である。

Endogenous information

- Look-ahead approx. and value function approx. generate values from simulation runs
 - Values observed for multiple runs are aggregated into scalar values → data mining task
 - Supervised learning methods depicts relation between features and resulting value
 - Basically, we classify an value (output) upon observed features (inputs)
 - Classification (discrete) and regression (continuous) as well as ANN can be used.
-
- Supervised learning methods depend on feature and variable type (regression/classification)
 - White-box and black-box approaches can be distinguished (decision tree/ANN)
 - One design issue is the linearity of the underlying model (regression vs. ANN)
 - Methods differ in the number of observations required for learning (decision tree/ANN)

日本語訳

- Endogenous information（この用語は講義スライド上の専門語として扱う）
- □ 先読み approx. and value function approx. generate values from シミュレーション runs
- □ Values observed for multiple runs are aggregated into scalar values □ data mining task（この用語は講義スライド上の専門語として扱う）
- □ Supervised learning methods depicts relation between features and resulting value（この用語は講義スライド上の専門語として扱う）
- □ Basically, we classify an value (output) upon observed features (inputs)（この用語は講義スライド上の専門語として扱う）
- □ Classification (discrete) and regression (continuous) as well as ANN can be used.（この用語は講義スライド上の専門語として扱う）
- □ Supervised learning methods depend on feature and variable type（この用語は講義スライド上の専門語として扱う）
- (regression/classification)（この用語は講義スライド上の専門語として扱う）
- □ White-box and black-box approaches can be distinguished (決定 tree/ANN)

試験対策ポイント

- ADP ではデータ生成、特微量、学習方法、評価が政策品質を左右する。
- feature selection と dimensionality reduction を区別する。

解説

このページでは「Endogenous information」を理解する。スライド上の表現は短い、試験では定義、具体例、モデル上の意味、手法の限界まで説明できる必要がある。

Analytics Issues in ADP では、ADP を動かすためのデータ分析上の問題を扱う。価値関数や方策を近似するには、状態、決定、外生情報、報酬、遷移のデータが必要である。実データだけでは不足する場合、シミュレーションで学習データを生成することもある。supervised learning は、入力と正解ラベルの対応から予測モデルを学ぶ方法である。VFA では、特微量を入力し、シミュレーションや DP で得た価値推定をラベルとして学習できる。unsupervised learning は、ラベルなしデータからクラスや低次元構造を見つける。状態集約や需要パターン分類で役立つ。

Feature selection は、既存の候補特徴から重要なものを選ぶことである。例えば車両位置、残り容量、残り時間、遅延注文数のうち、将来価値の説明に効くものを選ぶ。Dimensionality reduction は、既存特徴を組み合わせで新しい低次元表現を作ることである。PCA やオートエンコーダのような方法が該当する。


外生情報の生成では、過去データから分布を推定し、乱数で将来シナリオを生成する。旅行時間、需要発生、サービス時間などをサンプリングすることで、Rollout や VFA 学習に必要な未来パスを作る。ただし、分布仮定が間違っていると学習された方策も現実合わない。

試験では、ADP を単なる最適化手法としてではなく、データ分析・特微量設計・学習・シミュレーションが組み合わさったシステムとして説明する。特に feature selection と dimensionality reduction の違いは頻出であり、例を添えて説明する。

確認問題と解答

1. **L09-S022: 「Endogenous information」の概念を、定義・具体例・モデル上の意味の順に説明せよ。**
定義としては、ADP ではデータ生成、特微量、学習方法、評価が政策品質を左右する。具体例では、配送・在庫・フードデリバリーのような現実問題を扱い、状態、決定、外生情報、報酬、または情報モデル/意思決定モデルのどこに対応するかを明示する。モデル上の意味として、この概念が目的関数、制約、状態表現、将来価値、または方策選択にどのような影響を与えるかを書く。試験では、用語だけを列挙せず、入力データから意思決定、さらに現実の実装へつながる流れを文章で示すことが重要である。
2. **L09-S022: このスライドの考え方を、講義全体の DDDM プロセスの中に位置づけよ。**
DDDM プロセスでは、現実世界のデータを集約して情報モデルを作り、意思決定モデルまたは方策で行動を選び、実装後に結果を観測して次の状態へ進む。このスライドの概念は、そのどこか一部だけではなく、データ表現、意思決定、将来不確実性、計算可能性のいずれかに関わる。答えでは、まずこの概念がどの段階に属するかを述べ、次に他の段階へどう影響するかを書く。例えば価値関数なら将来価値を現在決定へ戻す役割、FIFO なら旅行時間情報モデルの整合性を保証する役割、CFA なら目的関数を調整して将来に良い行動を誘導する役割である。

Classification: Example with 2-Dim Input and 2 Classes



日本語訳

- Classification: 例 with 2-Dim Input and 2 Classes
- Training samples (この用語は講義スライド上の専門語として扱う)
- $\square 1, \square 1, \dots, \square \square, \square \square \in \mathbb{R}^2 \times \{0,1\}$
- Coordinate Class label (この用語は講義スライド上の専門語として扱う)
- Task (この用語は講義スライド上の専門語として扱う)
- Derive a hypothesis h that allows us (この用語は講義スライド上の専門語として扱う)
- to classify unlabeled data points (この用語は講義スライド上の専門語として扱う)
- $\square = \square(\square)$
- $\square$

試験対策ポイント

- ADP ではデータ生成、特徴量、学習方法、評価が政策品質を左右する。
- feature selection と dimensionality reduction を区別する。

解説

このページでは「Classification: Example with 2-Dim Input and 2 Classes」を理解する。スライド上の表現は短い、試験では定義、具体例、モデル上の意味、手法の限界まで説明できる必要がある。

Analytics Issues in ADP では、ADP を動かすためのデータ分析上の問題を扱う。価値関数や方策を近似するには、状態、決定、外生情報、報酬、遷移のデータが必要である。実データだけでは不足する場合、シミュレーションで学習データを生成することもある。

supervised learning は、入力と正解ラベルの対応から予測モデルを学ぶ方法である。VFA では、特徴量を入力し、シミュレーションや DP で得た価値推定をラベルとして学習できる。unsupervised learning は、ラベルなしデータからクラスや低次元構造を見つける。状態集約や需要パターン分類で役立つ。

Feature selection は、既存の候補特徴から重要なものを選ぶことである。例えば車両位置、残り容量、残り時間、遅延注文数のうち、将来価値の説明に効くものを選ぶ。Dimensionality reduction は、既存特徴を組み合わせで新しい低次元表現を作ることである。PCA やオートエンコーダのような方法が該当する。


外生情報の生成では、過去データから分布を推定し、乱数で将来シナリオを生成する。旅行時間、需要発生、サービス時間などをサンプリングすることで、Rollout や VFA 学習に必要な未来パスを作る。ただし、分布仮定が間違っていると学習された方策も現実合わない。

試験では、ADP を単なる最適化手法としてではなく、データ分析・特徴量設計・学習・シミュレーションが組み合わさったシステムとして説明する。特に feature selection と dimensionality reduction の違いは頻出であり、例を添えて説明する。

確認問題と解答

1. **L09-S023: 「Classification: Example with 2-Dim Input and 2 Classes」の概念を、定義・具体例・モデル上の意味の順に説明せよ。**
定義としては、ADP ではデータ生成、特徴量、学習方法、評価が政策品質を左右する。具体例では、配送・在庫・フードデリバリーのような現実問題を用い、状態、決定、外生情報、報酬、または情報モデル/意思決定モデルのどこに対応するかを明示する。モデル上の意味として、この概念が目的関数、制約、状態表現、将来価値、または方策選択にどのような影響を与えるかを書く。試験では、用語だけを列挙せず、入力データから意思決定、さらに現実の実装へつながる流れを文章で示すことが重要である。
2. **L09-S023: このスライドの考え方を、講義全体の DDDM プロセスの中に位置づけよ。**
DDDM プロセスでは、現実世界のデータを集約して情報モデルを作り、意思決定モデルまたは方策で行動を選び、実装後に結果を観測して次の状態へ進む。このスライドの概念は、そのどこか一部だけではなく、データ表現、意思決定、将来不確実性、計算可能性のいずれかに関わる。答えでは、まずこの概念がどの段階に属するかを述べ、次に他の段階へどう影響するかを書く。例えば価値関数なら将来価値を現在決定へ戻す役割、FIFO なら旅行時間情報モデルの整合性を保証する役割、CFA なら目的関数を調整して将来に良い行動を誘導する役割である。

Classification: Linear Regression



Linear Regression

$$\hat{y} = \theta + w^T x$$

Score Bias Weight Input

Using the score, we predict a class by

Orange if $\hat{y} > 0.5$
Red if $\hat{y} \leq 0.5$



Technische Universität Braunschweig

© Prof. Dr. Dirk C. Mattfeld

Data Driven Decision Making | Lecture 9 – Analytics Issues in ADP | Page 24



Decision Support
Institut für Wirtschaftsinformatik

日本語訳

- Classification: Linear Regression（この用語は講義スライド上の専門語として扱う）
- Linear Regression（この用語は講義スライド上の専門語として扱う）
- $\hat{y} = \theta + w^T x$
- $\hat{y}$
- Score Bias Weight Input（この用語は講義スライド上の専門語として扱う）
- Using the score, we predict a class by（この用語は講義スライド上の専門語として扱う）
- Orange if $\hat{y} > 0.5$ $\hat{y}$ （この用語は講義スライド上の専門語として扱う）
- Red if $\hat{y} \leq 0.5$ $\hat{y}$

試験対策ポイント

- ADP ではデータ生成、特徴量、学習方法、評価が政策品質を左右する。
- feature selection と dimensionality reduction を区別する。

解説

このページでは「Classification: Linear Regression」を理解する。スライド上の表現は短いが、試験では定義、具体例、モデル上の意味、手法の限界まで説明できる必要がある。

Analytics Issues in ADP では、ADP を動かすためのデータ分析上の問題を扱う。価値関数や方策を近似するには、状態、決定、外生情報、報酬、遷移のデータが必要である。実データだけでは不足する場合、シミュレーションで学習データを生成することもある。

supervised learning は、入力と正解ラベルの対応から予測モデルを学ぶ方法である。VFA では、特徴量を入力し、シミュレーションや DP で得た価値推定をラベルとして学習できる。unsupervised learning は、ラベルなしデータからクラスや低次元構造を見つける。状態集約や需要パターン分類で役立つ。

Feature selection は、既存の候補特徴から重要なものを選ぶことである。例えば車両位置、残り容量、残り時間、遅延注文数のうち、将来価値の説明に効くものを選ぶ。Dimensionality reduction は、既存特徴を組み合わせで新しい低次元表現を作ることである。PCA やオートエンコーダのような方法が該当する。


外生情報の生成では、過去データから分布を推定し、乱数で将来シナリオを生成する。旅行時間、需要発生、サービス時間などをサンプリングすることで、Rollout や VFA 学習に必要な未来パスを作る。ただし、分布仮定が間違っていると学習された方策も現実合わない。

試験では、ADP を単なる最適化手法としてではなく、データ分析・特徴量設計・学習・シミュレーションが組み合わさったシステムとして説明する。特に feature selection と dimensionality reduction の違いは頻出であり、例を添えて説明する。

確認問題と解答

1. **L09-S024: 「Classification: Linear Regression」の概念を、定義・具体例・モデル上の意味の順に説明せよ。**
定義としては、ADP ではデータ生成、特徴量、学習方法、評価が政策品質を左右する。。具体例では、配送・在庫・フードデリバリーのような現実問題を扱い、状態、決定、外生情報、報酬、または情報モデル/意思決定モデルのどこに対応するかを明示する。モデル上の意味として、この概念が目的関数、制約、状態表現、将来価値、または方策選択にどのような影響を与えるかを書く。試験では、用語だけを列挙せず、入力データから意思決定、さらに現実の実装へつながる流れを文章で示すことが重要である。
2. **L09-S024: このスライドの考え方を、講義全体の DDDM プロセスの中に位置づけよ。**
DDDM プロセスでは、現実世界のデータを集約して情報モデルを作り、意思決定モデルまたは方策で行動を選び、実装後に結果を観測して次の状態へ進む。このスライドの概念は、そのどこか一部だけではなく、データ表現、意思決定、将来不確実性、計算可能性のいずれかに関わる。答案では、まずこの概念がどの段階に属するかを述べ、次に他の段階へどう影響するかを書く。例えば価値関数なら将来価値を現在決定へ戻す役割、FIFO なら旅行時間情報モデルの整合性を保証する役割、CFA なら目的関数を調整して将来に良い行動を誘導する役割である。

Classification: Lookup-Table of Size 8x8



日本語訳

- Classification: Lookup-Table of Size 8x8 (この用語は講義スライド上の専門語として扱う)
- Table (この用語は講義スライド上の専門語として扱う)
- $\square = \square(\square \square)$
- $\square$
- Count vector Table 集約 Input
- A class is then predicted by (この用語は講義スライド上の専門語として扱う)
- Orange if $\square 0 > \square$ (この用語は講義スライド上の専門語として扱う)
- $\square \square \square$
- Red if $\square 1 \square \square$

試験対策ポイント

- ADP ではデータ生成、特徴量、学習方法、評価が政策品質を左右する。
- feature selection と dimensionality reduction を区別する。

解説

このページでは「Classification: Lookup-Table of Size 8x8」を理解する。スライド上の表現は短い、試験では定義、具体例、モデル上の意味、手法の限界まで説明できる必要がある。

Analytics Issues in ADP では、ADP を動かすためのデータ分析上の問題を扱う。価値関数や方策を近似するには、状態、決定、外生情報、報酬、遷移のデータが必要である。実データだけでは不足する場合、シミュレーションで学習データを生成することもある。

supervised learning は、入力と正解ラベルの対応から予測モデルを学ぶ方法である。VFA では、特徴量を入力し、シミュレーションや DP で得た価値推定をラベルとして学習できる。unsupervised learning は、ラベルなしデータからクラスや低次元構造を見つける。状態集約や需要パターン分類で役立つ。

Feature selection は、既存の候補特徴から重要なものを選ぶことである。例えば車両位置、残り容量、残り時間、遅延注文数のうち、将来価値の説明に効くものを選ぶ。Dimensionality reduction は、既存特徴を組み合わせで新しい低次元表現を作ることである。PCA やオートエンコーダのような方法が該当する。


外生情報の生成では、過去データから分布を推定し、乱数で将来シナリオを生成する。旅行時間、需要発生、サービス時間などをサンプリングすることで、Rollout や VFA 学習に必要な未来パスを作る。ただし、分布仮定が間違っていると学習された方策も現実合わない。

試験では、ADP を単なる最適化手法としてではなく、データ分析・特徴量設計・学習・シミュレーションが組み合わさったシステムとして説明する。特に feature selection と dimensionality reduction の違いは頻出であり、例を添えて説明する。

確認問題と解答

1. **L09-S025: 「Classification: Lookup-Table of Size 8x8」の概念を、定義・具体例・モデル上の意味の順に説明せよ。**
定義としては、ADP ではデータ生成、特徴量、学習方法、評価が政策品質を左右する。。具体例では、配送・在庫・フードデリバリーのような現実問題を扱い、状態、決定、外生情報、報酬、または情報モデル/意思決定モデルのどこに対応するかを明示する。モデル上の意味として、この概念が目的関数、制約、状態表現、将来価値、または方策選択にどのような影響を与えるかを書く。試験では、用語だけを列挙せず、入力データから意思決定、さらに現実の実装へつながる流れを文章で示すことが重要である。
2. **L09-S025: このスライドの考え方を、講義全体の DDDM プロセスの中に位置づけよ。**
DDDM プロセスでは、現実世界のデータを集約して情報モデルを作り、意思決定モデルまたは方策で行動を選び、実装後に結果を観測して次の状態へ進む。このスライドの概念は、そのどこか一部だけではなく、データ表現、意思決定、将来不確実性、計算可能性のいずれかに関わる。答えでは、まずこの概念がどの段階に属するかを述べ、次に他の段階へどう影響するかを書く。例えば価値関数なら将来価値を現在決定へ戻す役割、FIFO なら旅行時間情報モデルの整合性を保証する役割、CFA なら目的関数を調整して将来に良い行動を誘導する役割である。

Classification: Decision Tree with 29 Leaves



解説

このページでは「Classification: Decision Tree with 29 Leaves」を理解する。スライド上の表現は短いが、試験では定義、具体例、モデル上の意味、手法の限界まで説明できる必要がある。

Analytics Issues in ADP では、ADP を動かすためのデータ分析上の問題を扱う。価値関数や方策を近似するには、状態、決定、外生情報、報酬、遷移のデータが必要である。実データだけでは不足する場合、シミュレーションで学習データを生成することもある。

supervised learning は、入力と正解ラベルの対応から予測モデルを学ぶ方法である。VFA では、特徴量を入力し、シミュレーションや DP で得た価値推定をラベルとして学習できる。unsupervised learning は、ラベルなしデータからクラスや低次元構造を見つける。状態集約や需要パターン分類で役立つ。

Feature selection は、既存の候補特徴から重要なものを選ぶことである。例えば車両位置、残り容量、残り時間、遅延注文数のうち、将来価値の説明に効くものを選ぶ。Dimensionality reduction は、既存特徴を組み合わせて新しい低次元表現を作ることである。PCA やオートエンコーダのような方法が該当する。

外生情報の生成では、過去データから分布を推定し、乱数で将来シナリオを生成する。旅行時間、需要発生、サービス時間などをサンプリングすることで、Rollout や VFA 学習に必要な未来パスを作る。ただし、分布仮定が間違っていると学習された方策も現実合わない。

試験では、ADP を単なる最適化手法としてではなく、データ分析・特徴量設計・学習・シミュレーションが組み合わさったシステムとして説明する。特に feature selection と dimensionality reduction の違いは頻出であり、例を添えて説明する。

日本語訳

- Classification: 決定 Tree with 29 Leaves
- 1 □2 □3 □4 □5 決定 Tree
-
- = □ □ □ □ □ □ □ □
-
- 7 □8 □9 □10 □=□
- 6
- Probability Vector of class 1 if x is in leaf □□, (この用語は講義スライド上の専門語として扱う)
- vector probabilities 0 else (この用語は講義スライド上の専門語として扱う)

試験対策ポイント

- ADP ではデータ生成、特徴量、学習方法、評価が政策品質を左右する。
- feature selection と dimensionality reduction を区別する。

確認問題と解答

- L09-S026: 「Classification: Decision Tree with 29 Leaves」の概念を、定義・具体例・モデル上の意味の順に説明せよ。**
定義としては、ADP ではデータ生成、特徴量、学習方法、評価が政策品質を左右する。。具体例では、配送・在庫・フードデリバリーのような現実問題を扱い、状態、決定、外生情報、報酬、または情報モデル/意思決定モデルのどこに対応するかを明示する。モデル上の意味として、この概念が目的関数、制約、状態表現、将来価値、または方策選択にどのような影響を与えるかを書く。試験では、用語だけを列挙せず、入力データから意思決定、さらに現実の実装へつながる流れを文章で示すことが重要である。
- L09-S026: このスライドの考え方を、講義全体の DDDM プロセスの中に位置づけよ。**
DDDM プロセスでは、現実世界のデータを集約して情報モデルを作り、意思決定モデルまたは方策で行動を選び、実装後に結果を観測して次の状態へ進む。このスライドの概念は、そのどこか一部だけではなく、データ表現、意思決定、将来不確実性、計算可能性のいずれかに関わる。答えでは、まずこの概念がどの段階に属するかを述べ、次に他の段階へどう影響するかを書く。例えば価値関数なら将来価値を現在決定へ戻す役割、FIFO なら旅行時間情報モデルの整合性を保証する役割、CFA なら目的関数を調整して将来に良い行動を誘導する役割である。

Advanced Methods: Gradient Boosted Decision Trees

- **Reminder** A decision tree is noted by $F(x; p, I) := \sum_{k=1}^K p_k \cdot \mathbb{I}_{\{x \in I_k\}}$
- **Problem** A single decision tree is prone to overfitting
- **Solution** Fit several small trees and use them as an ensemble
- Iterative procedure $F_m(x) = F_{m-1}(x) + \alpha_m \underbrace{\sum_{j=1}^J p_{jm} \mathbb{I}_{\{x \in I_{jm}\}}}_{\text{Fit the residual of } F_{m-1}}$

日本語訳

- Advanced Methods: Gradient Boosted 決定 Trees
- □ Reminder A 決定 tree is noted by □ □; □, □ □ □ □
- □=1 □ □ □ □ □ □ □ □
- □ Problem A single 決定 tree is prone to overfitting
- □ Solution Fit several small trees and use them as an ensemble (この用語は講義スライド上の専門語として扱う)
- □
- □ Iterative procedure □ □ □ = □ □ □ 1 □ + □ □ □ □=1 □ □ □ □ □ □ □ □ □ □ (この用語は講義スライド上の専門語として扱う)
- Fit the residual of □ □ □ 1 (この用語は講義スライド上の専門語として扱う)

試験対策ポイント

- ADP ではデータ生成、特微量、学習方法、評価が政策品質を左右する。
- feature selection と dimensionality reduction を区別する。

解説

このページでは「Advanced Methods: Gradient Boosted Decision Trees」を理解する。スライド上の表現は短いが、試験では定義、具体例、モデル上の意味、手法の限界まで説明できる必要がある。

Analytics Issues in ADP では、ADP を動かすためのデータ分析上の問題を扱う。価値関数や方策を近似するには、状態、決定、外生情報、報酬、遷移のデータが必要である。実データだけでは不足する場合、シミュレーションで学習データを生成することもある。

supervised learning は、入力と正解ラベルの対応から予測モデルを学ぶ方法である。VFA では、特微量を入力し、シミュレーションや DP で得た価値推定をラベルとして学習できる。unsupervised learning は、ラベルなしデータからクラスタや低次元構造を見つける。状態集約や需要パターン分類で役立つ。

Feature selection は、既存の候補特徴から重要なものを選ぶことである。例えば車両位置、残り容量、残り時間、遅延注文数のうち、将来価値の説明に効くものを選ぶ。Dimensionality reduction は、既存特徴を組み合わせて新しい低次元表現を作ることである。PCA やオートエンコーダのような方法が該当する。

外生情報の生成では、過去データから分布を推定し、乱数で将来シナリオを生成する。旅行時間、需要発生、サービス時間などをサンプリングすることで、Rollout や VFA 学習に必要な未来パスを作る。ただし、分布仮定が間違っていると学習された方策も現実合わない。

試験では、ADP を単なる最適化手法としてではなく、データ分析・特微量設計・学習・シミュレーションが組み合わさったシステムとして説明する。特に feature selection と dimensionality reduction の違いは頻出であり、例を添えて説明する。

確認問題と解答

1. **L09-S027: 「Advanced Methods: Gradient Boosted Decision Trees」の概念を、定義・具体例・モデル上の意味の順に説明せよ。**
定義としては、ADP ではデータ生成、特微量、学習方法、評価が政策品質を左右する。。具体例では、配送・在庫・フードデリバリーのような現実問題を扱い、状態、決定、外生情報、報酬、または情報モデル/意思決定モデルのどこに対応するかを明示する。モデル上の意味として、この概念が目的関数、制約、状態表現、将来価値、または方策選択にどのような影響を与えるかを書く。試験では、用語だけを列挙せず、入力データから意思決定、さらに現実の実装へつながる流れを文章で示すことが重要である。
2. **L09-S027: このスライドの考え方を、講義全体の DDDM プロセスの中に位置づけよ。**
DDDМ プロセスでは、現実世界のデータを集約して情報モデルを作り、意思決定モデルまたは方策で行動を選び、実装後に結果を観測して次の状態へ進む。このスライドの概念は、そのどこか一部だけではなく、データ表現、意思決定、将来不確実性、計算可能性のいずれかに関わる。答案では、まずこの概念がどの段階に属するかを述べ、次に他の段階へどう影響するかを書く。例えば価値関数なら将来価値を現在決定へ戻す役割、FIFO なら旅行時間情報モデルの整合性を保証する役割、CFA なら目的関数を調整して将来に良い行動を誘導する役割である。

Advanced Methods: Neural Network

▪ Reminder	Linear Regression $\hat{y} = \theta + w^T x$
▪ Problem	Can only express linear relations
▪ Solution	Stack several linear layers $\theta + w^T x$ and introduce non-linearity via an activation function, e.g., $ReLU(x) = \max(0, x)$



日本語訳

- Advanced Methods: Neural Network（この用語は講義スライド上の専門語として扱う）
- ◻ ◻ Reminder Linear Regression $\hat{y} = \theta + w^T x$ （この用語は講義スライド上の専門語として扱う）
- ◻ ◻ Problem Can only express linear relations（この用語は講義スライド上の専門語として扱う）
- ◻ ◻ Solution Stack several linear layers $\theta + w^T x$ and introduce non-linearity（この用語は講義スライド上の専門語として扱う）
- via an activation function, e.g., $ReLU(x) = \max(0, x)$ （この用語は講義スライド上の専門語として扱う）

試験対策ポイント

- ADP ではデータ生成、特徴量、学習方法、評価が政策品質を左右する。
- feature selection と dimensionality reduction を区別する。

解説

このページでは「Advanced Methods: Neural Network」を理解する。スライド上の表現は短いが、試験では定義、具体例、モデル上の意味、手法の限界まで説明できる必要がある。

Analytics Issues in ADP では、ADP を動かすためのデータ分析上の問題を扱う。価値関数や方策を近似するには、状態、決定、外生情報、報酬、遷移のデータが必要である。実データだけでは不足する場合、シミュレーションで学習データを生成することもある。

supervised learning は、入力と正解ラベルの対応から予測モデルを学ぶ方法である。VFA では、特徴量を入力し、シミュレーションや DP で得た価値推定をラベルとして学習できる。unsupervised learning は、ラベルなしデータからクラスタや低次元構造を見つける。状態集約や需要パターン分類で役立つ。

Feature selection は、既存の候補特徴から重要なものを選ぶことである。例えば車両位置、残り容量、残り時間、遅延注文数のうち、将来価値の説明に効くものを選ぶ。Dimensionality reduction は、既存特徴を組み合わせで新しい低次元表現を作ることである。PCA やオートエンコーダのような方法が該当する。


外生情報の生成では、過去データから分布を推定し、乱数で将来シナリオを生成する。旅行時間、需要発生、サービス時間などをサンプリングすることで、Rollout や VFA 学習に必要な未来パスを作る。ただし、分布仮定が間違っていると学習された方策も現実合わない。

試験では、ADP を単なる最適化手法としてではなく、データ分析・特徴量設計・学習・シミュレーションが組み合わさったシステムとして説明する。特に feature selection と dimensionality reduction の違いは頻出であり、例を添えて説明する。

確認問題と解答

1. **L09-S028: 「Advanced Methods: Neural Network」の概念を、定義・具体例・モデル上の意味の順に説明せよ。**
定義としては、ADP ではデータ生成、特徴量、学習方法、評価が政策品質を左右する。。具体例では、配送・在庫・フードデリバリーのような現実問題を扱い、状態、決定、外生情報、報酬、または情報モデル/意思決定モデルのどこに対応するかを明示する。モデル上の意味として、この概念が目的関数、制約、状態表現、将来価値、または方策選択にどのような影響を与えるかを書く。試験では、用語だけを列挙せず、入力データから意思決定、さらに現実の実装へつながる流れを文章で示すことが重要である。
2. **L09-S028: このスライドの考え方を、講義全体の DDDM プロセスの中に位置づけよ。**
DDDM プロセスでは、現実世界のデータを集約して情報モデルを作り、意思決定モデルまたは方策で行動を選び、実装後に結果を観測して次の状態へ進む。このスライドの概念は、そのどこか一部だけではなく、データ表現、意思決定、将来不確実性、計算可能性のいずれかに関わる。答案では、まずこの概念がどの段階に属するかを述べ、次に他の段階へどう影響するかを書く。例えば価値関数なら将来価値を現在決定へ戻す役割、FIFO なら旅行時間情報モデルの整合性を保証する役割、CFA なら目的関数を調整して将来に良い行動を誘導する役割である。

Advanced Methods: Neural Network



Output of a neuron

$$a_j^l = \sigma \left[\sum_k w_{jk}^l \cdot a_k^{l-1} + \theta_j^l \right]$$

Output of a layer

$$a^l = \sigma(w^l a^{l-1} + \theta^l)$$

解説

このページでは「Advanced Methods: Neural Network」を理解する。スライド上の表現は短いが、試験では定義、具体例、モデル上の意味、手法の限界まで説明できる必要がある。

Analytics Issues in ADP では、ADP を動かすためのデータ分析上の問題を扱う。価値関数や方策を近似するには、状態、決定、外生情報、報酬、遷移のデータが必要である。実データだけでは不足する場合、シミュレーションで学習データを生成することもある。

supervised learning は、入力と正解ラベルの対応から予測モデルを学ぶ方法である。VFA では、特徴量を入力し、シミュレーションや DP で得た価値推定をラベルとして学習できる。unsupervised learning は、ラベルなしデータからクラスや低次元構造を見つける。状態集約や需要パターン分類で役立つ。

Feature selection は、既存の候補特徴から重要なものを選ぶことである。例えば車両位置、残り容量、残り時間、遅延注文数のうち、将来価値の説明に効くものを選ぶ。Dimensionality reduction は、既存特徴を組み合わせで新しい低次元表現を作ることである。PCA やオートエンコーダのような方法が該当する。

外生情報の生成では、過去データから分布を推定し、乱数で将来シナリオを生成する。旅行時間、需要発生、サービス時間などをサンプリングすることで、Rollout や VFA 学習に必要な未来パスを作る。ただし、分布仮定が間違っていると学習された方策も現実合わない。

試験では、ADP を単なる最適化手法としてではなく、データ分析・特徴量設計・学習・シミュレーションが組み合わさったシステムとして説明する。特に feature selection と dimensionality reduction の違いは頻出であり、例を添えて説明する。

確認問題と解答

1. **L09-S029: 「Advanced Methods: Neural Network」の概念を、定義・具体例・モデル上の意味の順に説明せよ。**

定義としては、ADP ではデータ生成、特徴量、学習方法、評価が政策品質を左右する。具体例では、配送・在庫・フードデリバリーのような現実問題を扱い、状態、決定、外生情報、報酬、または情報モデル/意思決定モデルのどこに対応するかを明示する。モデル上の意味として、この概念が目的関数、制約、状態表現、将来価値、または方策選択にどのような影響を与えるかを書く。試験では、用語だけを列挙せず、入力データから意思決定、さらに現実の実装へつながる流れを文章で示すことが重要である。

2. **L09-S029: このスライドの考え方を、講義全体の DDDM プロセスの中に位置づけよ。**

DDDM プロセスでは、現実世界のデータを集約して情報モデルを作り、意思決定モデルまたは方策で行動を選び、実装後に結果を観測して次の状態へ進む。このスライドの概念は、そのどこか一部だけではなく、データ表現、意思決定、将来不確実性、計算可能性のいずれかに関わる。答えでは、まずこの概念がどの段階に属するかを述べ、次に他の段階へどう影響するかを書く。例えば価値関数なら将来価値を現在決定へ戻す役割、FIFO なら旅行時間情報モデルの整合性を保証する役割、CFA なら目的関数を調整して将来に良い行動を誘導する役割である。


日本語訳

- Advanced Methods: Neural Network (この用語は講義スライド上の専門語として扱う)
- □=1 □=2 □=3 □=4
- Output of a neuron (この用語は講義スライド上の専門語として扱う)
- □□□ = □ □ □□□
- □
- □ □□□1 + □□□
- □
- Output of a layer (この用語は講義スライド上の専門語として扱う)
- □□ = □(□ □ □□□1 + □ □)

試験対策ポイント

- ADP ではデータ生成、特徴量、学習方法、評価が政策品質を左右する。
- feature selection と dimensionality reduction を区別する。

Advanced Methods: Neural Network – Tuning



Also consider varying:

- Learning rate / Learning rate schedule
- Batch size
- Weight initialization
- Optimizer

Code available at:

https://github.com/flohilde/fm_lecture

日本語訳

- Advanced Methods: Neural Network –Tuning（この用語は講義スライド上の専門語として扱う）
- Increase nodes per layer（この用語は講義スライド上の専門語として扱う）
- Increase number of layers（この用語は講義スライド上の専門語として扱う）
- Also consider varying:（この用語は講義スライド上の専門語として扱う）
- Learning rate / Learning rate（この用語は講義スライド上の専門語として扱う）
- schedule（この用語は講義スライド上の専門語として扱う）
- Batch size（この用語は講義スライド上の専門語として扱う）
- Weight initialization（この用語は講義スライド上の専門語として扱う）
- Optimizer（この用語は講義スライド上の専門語として扱う）

試験対策ポイント

- ADP ではデータ生成、特徴量、学習方法、評価が政策品質を左右する。
- feature selection と dimensionality reduction を区別する。

解説

このページでは「Advanced Methods: Neural Network –Tuning」を理解する。スライド上の表現は短いですが、試験では定義、具体例、モデル上の意味、手法の限界まで説明できる必要がある。

Analytics Issues in ADP では、ADP を動かすためのデータ分析上の問題を扱う。価値関数や方策を近似するには、状態、決定、外生情報、報酬、遷移のデータが必要である。実データだけでは不足する場合、シミュレーションで学習データを生成することもある。

supervised learning は、入力と正解ラベルの対応から予測モデルを学ぶ方法である。VFA では、特徴量を入力し、シミュレーションや DP で得た価値推定をラベルとして学習できる。unsupervised learning は、ラベルなしデータからクラスや低次元構造を見つける。状態集約や需要パターン分類で役立つ。

Feature selection は、既存の候補特徴から重要なものを選ぶことである。例えば車両位置、残り容量、残り時間、遅延注文数のうち、将来価値の説明に効くものを選ぶ。Dimensionality reduction は、既存特徴を組み合わせで新しい低次元表現を作ることである。PCA やオートエンコーダのような方法が該当する。

外生情報の生成では、過去データから分布を推定し、乱数で将来シナリオを生成する。旅行時間、需要発生、サービス時間などをサンプリングすることで、Rollout や VFA 学習に必要な未来パスを作る。ただし、分布仮定が間違っていると学習された方策も現実合わない。

試験では、ADP を単なる最適化手法としてではなく、データ分析・特徴量設計・学習・シミュレーションが組み合わさったシステムとして説明する。特に feature selection と dimensionality reduction の違いは頻出であり、例を添えて説明する。

確認問題と解答

1. **L09-S030: 「Advanced Methods: Neural Network –Tuning」の概念を、定義・具体例・モデル上の意味の順に説明せよ。**

定義としては、ADP ではデータ生成、特徴量、学習方法、評価が政策品質を左右する。。具体例では、配送・在庫・フードデリバリーのような現実問題を扱い、状態、決定、外生情報、報酬、または情報モデル/意思決定モデルのどこに対応するかを明示する。モデル上の意味として、この概念が目的関数、制約、状態表現、将来価値、または方策選択にどのような影響を与えるかを書く。試験では、用語だけを列挙せず、入力データから意思決定、さらに現実の実装へつながる流れを文章で示すことが重要である。

2. **L09-S030: このスライドの考え方を、講義全体の DDDM プロセスの中に位置づけよ。**

DDDM プロセスでは、現実世界のデータを集約して情報モデルを作り、意思決定モデルまたは方策で行動を選び、実装後に結果を観測して次の状態へ進む。このスライドの概念は、そのどこか一部だけではなく、データ表現、意思決定、将来不確実性、計算可能性のいずれかに関わる。答えでは、まずこの概念がどの段階に属するかを述べ、次に他の段階へどう影響するかを書く。例えば価値関数なら将来価値を現在決定へ戻す役割、FIFO なら旅行時間情報モデルの整合性を保証する役割、CFA なら目的関数を調整して将来に良い行動を誘導する役割である。

Some Words of Advice

- Start with a simple model to setup a benchmark. Then try out more complex models and compare them to your benchmark.
A possible progression: Linear regression → Gradient boosted decision tree → ANN
- When employing a complex method, train on a few thousand data points. It should be able to learn them by heart.
- Once you have a good model you can start fine-tuning. Only fine-tune hyperparameters that you actually understand and for which you can set reasonable ranges.
- Never resort to grid-search! Random-search and Bayesian optimization are much more sample efficient. Also, do use cross-validation.
- For neural networks: Architecture over hyperparameters!



Data Driven Decision Making | Lecture 9 – Analytics Issues in ADP | Page 31



日本語訳

- Some Words of Advice (この用語は講義スライド上の専門語として扱う)
- Start with a simple model to setup a benchmark. Then try out more complex models and (この用語は講義スライド上の専門語として扱う)
- compare them to your benchmark. (この用語は講義スライド上の専門語として扱う)
- A possible progression: Linear regression □ Gradient boosted 決定 tree □ ANN
- When employing a complex method, train on a few thousand data points. It should be able (この用語は講義スライド上の専門語として扱う)
- to learn them by heart. (この用語は講義スライド上の専門語として扱う)
- Once you have a good model you can start fine-tuning. Only fine-tune hyperparameters (この用語は講義スライド上の専門語として扱う)
- that you actually understand and for which you can set reasonable ranges. (この用語は講義スライド上の専門語として扱う)
- Never resort to grid-search! Random-search and Bayesian optimization are much more (この用語は講義スライド上の専門語として扱う)

試験対策ポイント

- ADP ではデータ生成、特徴量、学習方法、評価が政策品質を左右する。
- feature selection と dimensionality reduction を区別する。

解説

このページでは「Some Words of Advice」を理解する。スライド上の表現は短いですが、試験では定義、具体例、モデル上の意味、手法の限界まで説明できる必要がある。

Analytics Issues in ADP では、ADP を動かすためのデータ分析上の問題を扱う。価値関数や方策を近似するには、状態、決定、外生情報、報酬、遷移のデータが必要である。実データだけでは不足する場合、シミュレーションで学習データを生成することもある。supervised learning は、入力と正解ラベルの対応から予測モデルを学ぶ方法である。VFA では、特徴量を入力し、シミュレーションや DP で得た価値推定をラベルとして学習できる。unsupervised learning は、ラベルなしデータからクラスや低次元構造を見つける。状態集約や需要パターン分類で役立つ。

Feature selection は、既存の候補特徴から重要なものを選ぶことである。例えば車両位置、残り容量、残り時間、遅延注文数のうち、将来価値の説明に効くものを選ぶ。Dimensionality reduction は、既存特徴を組み合わせで新しい低次元表現を作ることである。PCA やオートエンコーダのような方法が該当する。

外生情報の生成では、過去データから分布を推定し、乱数で将来シナリオを生成する。旅行時間、需要発生、サービス時間などをサンプリングすることで、Rollout や VFA 学習に必要な未来パスを作る。ただし、分布仮定が間違っていると学習された方策も現実合わない。

試験では、ADP を単なる最適化手法としてではなく、データ分析・特徴量設計・学習・シミュレーションが組み合わさったシステムとして説明する。特に feature selection と dimensionality reduction の違いは頻出であり、例を添えて説明する。

確認問題と解答

- L09-S031: 「Some Words of Advice」の概念を、定義・具体例・モデル上の意味の順に説明せよ。**
定義としては、ADP ではデータ生成、特徴量、学習方法、評価が政策品質を左右する。。具体例では、配送・在庫・フードデリバリーのような現実問題を扱い、状態、決定、外生情報、報酬、または情報モデル/意思決定モデルのどこに対応するかを明示する。モデル上の意味として、この概念が目的関数、制約、状態表現、将来価値、または方策選択にどのような影響を与えるかを書く。試験では、用語だけを列挙せず、入力データから意思決定、さらに現実の実装へつながる流れを文章で示すことが重要である。
- L09-S031: このスライドの考え方を、講義全体の DDDM プロセスの中に位置づけよ。**
DDDM プロセスでは、現実世界のデータを集約して情報モデルを作り、意思決定モデルまたは方策で行動を選び、実装後に結果を観測して次の状態へ進む。このスライドの概念は、そのどこか一部だけではなく、データ表現、意思決定、将来不確実性、計算可能性のいずれかに関わる。答案では、まずこの概念がどの段階に属するかを述べ、次に他の段階へどう影響するかを書く。例えば価値関数なら将来価値を現在決定へ戻す役割、FIFO なら旅行時間情報モデルの整合性を保証する役割、CFA なら目的関数を調整して将来に良い行動を誘導する役割である。

Summary of lecture

- Simulation based methods (look-ahead, VFA) make use of descriptive analytics
- The size of the post-decision space of a problem can be lowered by dim. reduction
- Learn relation between features observed in the simulation and an expected future reward
- Generally, analytics provides generic approaches to design of ADP methods



Data Driven Decision Making | Lecture 9 – Analytics Issues in ADP | Page 32



日本語訳

- Summary of lecture（この用語は講義スライド上の専門語として扱う）
- □ シミュレーション based methods (先読み, VFA) make use of descriptive analytics
- □ The size of the post-決定 space of a problem can be lowered by dim. reduction
- □ Learn relation between features observed in the シミュレーション and an 期待される future 報酬
- □ Generally, analytics provides generic approaches to design of ADP methods（この用語は講義スライド上の専門語として扱う）

試験対策ポイント

- ADP ではデータ生成、特徴量、学習方法、評価が政策品質を左右する。
- feature selection と dimensionality reduction を区別する。

解説

このページでは「Summary of lecture」を理解する。スライド上の表現は短い、試験では定義、具体例、モデル上の意味、手法の限界まで説明できる必要がある。

Analytics Issues in ADP では、ADP を動かすためのデータ分析上の問題を扱う。価値関数や方策を近似するには、状態、決定、外生情報、報酬、遷移のデータが必要である。実データだけでは不足する場合、シミュレーションで学習データを生成することもある。supervised learning は、入力と正解ラベルの対応から予測モデルを学ぶ方法である。VFA では、特徴量を入力し、シミュレーションや DP で得た価値推定をラベルとして学習できる。unsupervised learning は、ラベルなしデータからクラスや低次元構造を見つける。状態集約や需要パターン分類で役立つ。

Feature selection は、既存の候補特徴から重要なものを選ぶことである。例えば車両位置、残り容量、残り時間、遅延注文数のうち、将来価値の説明に効くものを選ぶ。Dimensionality reduction は、既存特徴を組み合わせで新しい低次元表現を作ることである。PCA やオートエンコーダのような方法が該当する。

外生情報の生成では、過去データから分布を推定し、乱数で将来シナリオを生成する。旅行時間、需要発生、サービス時間などをサンプリングすることで、Rollout や VFA 学習に必要な未来パスを作る。ただし、分布仮定が間違っていると学習された方策も現実合わない。

試験では、ADP を単なる最適化手法としてではなく、データ分析・特徴量設計・学習・シミュレーションが組み合わさったシステムとして説明する。特に feature selection と dimensionality reduction の違いは頻出であり、例を添えて説明する。

確認問題と解答

1. **L09-S032: 「Summary of lecture」の概念を、定義・具体例・モデル上の意味の順に説明せよ。**
定義としては、ADP ではデータ生成、特徴量、学習方法、評価が政策品質を左右する。。具体例では、配送・在庫・フードデリバリーのような現実問題を扱い、状態、決定、外生情報、報酬、または情報モデル/意思決定モデルのどこに対応するかを明示する。モデル上の意味として、この概念が目的関数、制約、状態表現、将来価値、または方策選択にどのような影響を与えるかを書く。試験では、用語だけを列挙せず、入力データから意思決定、さらに現実の実装へつながる流れを文章で示すことが重要である。
2. **L09-S032: このスライドの考え方を、講義全体の DDDM プロセスの中に位置づけよ。**
DDDM プロセスでは、現実世界のデータを集約して情報モデルを作り、意思決定モデルまたは方策で行動を選び、実装後に結果を観測して次の状態へ進む。このスライドの概念は、そのどこか一部だけではなく、データ表現、意思決定、将来不確実性、計算可能性のいずれかに関わる。答案では、まずこの概念がどの段階に属するかを述べ、次に他の段階へどう影響するかを書く。例えば価値関数なら将来価値を現在決定へ戻す役割、FIFO なら旅行時間情報モデルの整合性を保証する役割、CFA なら目的関数を調整して将来に良い行動を誘導する役割である。

関連知識を一通り説明した後に置く独立演習ページである。スライドページには同じ過去問を繰り返さない。

SS25 Exercise 5 (4 点)

問題内容

feature selection と dimensionality reduction の違い。設問では、特徴量を選ぶのか、新しい低次元表現に変換するのかを例で区別すること。ことが求められる。

満点答案

満点答案では、VFA が状態または後決定状態の将来価値を特徴量から近似する方法であると説明する。決定評価では $R(S,x) + \hat{V}(S^x)$ を使う。特徴量には残り需要、リソース余裕、時間、位置、需要密度などがあり、feature selection と dimensionality reduction を区別する。

具体例による解説

具体例として、配送問題なら、顧客注文・車両位置・旅行時間を情報モデルにし、訪問順や割当を意思決定モデルで決める。在庫問題なら、在庫水準を状態、注文量を決定、需要を外生情報、在庫更新式を遷移、欠品費・保管費を費用として整理する。問題文の文脈に合わせて、抽象用語を必ず具体的な変数や行動に置き換える。

採点で落とさない要素

- ・ 設問が求める概念の定義を最初に明確に書く。
- ・ 講義の専門語を列挙するだけでなく、現実例とモデル要素へ対応付ける。
- ・ 利点だけでなく限界・注意点も最低一つ述べる。
- ・ 式が出る問題では、記号の意味を文章で説明する。
- ・ 新しい事例問題では、状態・決定・外生情報・遷移・報酬/費用の順に整理する。